

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN - TIN

ĐỒ ÁN TỐT NGHIỆP

**Nghiên cứu và xây dựng hệ thống phân tích đa
phương thức hỗ trợ chẩn đoán bệnh da liễu tích hợp
hỏi đáp trực quan y tế**

Nguyễn Thị Hương Giang
Email: Giang.NTH227106@sis.hust.edu.vn
Mã sinh viên: 20227106
Chuyên ngành Toán - Tin

Giảng viên hướng dẫn: TS. Ngô Quốc Hoàn

Chữ kí GVHD

HÀ NỘI, 06/2026

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

1. Mục tiêu và nội dung của đề án

- Nghiên cứu lý thuyết:** Tìm hiểu các kiến trúc học sâu (DeepLabV3+, EfficientNet-B1), cơ chế giải thích AI (Grad-CAM) và truy xuất tri thức y văn (RAG).
- Phát triển hệ thống:** Xây dựng Pipeline đa nhiệm tích hợp phân đoạn đa tỷ lệ, phân loại 7 lớp bệnh lý sắc tố và hợp nhất xác suất Bayes đa phương thức.
- Triển khai ứng dụng:** Phát triển Dashboard chẩn đoán thời gian thực, tích hợp quản lý hồ sơ EHR trên Cloud Firestore và xuất báo cáo PDF y khoa.

2. Kết quả đạt được

- Hiệu năng tối ưu:** Đạt Dice Score 0,9132 (phân đoạn) và Accuracy 95,01% (phân loại), xử lý hiệu quả bài toán mất cân bằng dữ liệu y tế cực đoan.
- Đột phá VQA:** Tối ưu trợ lý y khoa qua LoRA (chỉ dùng 2,13% tham số) và RAG, đảm bảo phản hồi y văn chính xác và an toàn.
- Vận hành thực tế:** Hệ thống chạy mượt mà (232 ms), minh bạch hóa quyết định qua Grad-CAM và bảo vệ người dùng bằng các cổng lọc an toàn.

3. Ý thức làm việc của sinh viên:

- Có tinh thần học hỏi, có khả năng làm việc độc lập.
- Có kỹ năng xây dựng và thiết kế đề cương nghiên cứu. Có nền tảng trong nghiên cứu các lĩnh vực về nhận dạng bệnh lý da liễu.
- Có kỹ năng viết và tổng hợp báo cáo trong nghiên cứu khoa học.

Hà Nội, ngày 26 tháng 6 năm 2026

Giảng viên hướng dẫn

TS. Ngô Quốc Hoàn

Lời cảm ơn

Lời đầu tiên, em xin được bày tỏ lòng biết ơn sâu sắc đến Ban Giám đốc **Đại học Bách khoa Hà Nội**, cùng toàn thể quý Thầy, Cô giáo khoa **Toán - Tin** đã tận tình truyền đạt những kiến thức quý báu, tạo mọi điều kiện thuận lợi và giúp đỡ em trong suốt quá trình học tập, rèn luyện tại trường. Những kiến thức tích lũy được trên giảng đường chính là nền tảng vững chắc giúp em hoàn thành đồ án này. Đặc biệt, em xin gửi lời cảm ơn chân thành và sâu sắc nhất tới **TS. Ngô Quốc Hoàn** - người đã trực tiếp hướng dẫn, định hướng đề tài và tận tình chỉ bảo, giúp đỡ em trong suốt quá trình nghiên cứu và thực hiện đề tài. Sự đồng hành, những lời khuyên chuyên môn quý giá cùng sự động viên của Thầy là động lực lớn nhất để em vượt qua những khó khăn trong suốt chặng đường qua. Em cũng xin gửi lời cảm ơn tới các bạn đã luôn chia sẻ tài liệu, đóng góp ý kiến và động viên em trong học tập cũng như trong quá trình thực hiện đồ án tốt nghiệp. Cuối cùng, em xin bày tỏ lòng biết ơn vô hạn đối với gia đình - chỗ dựa tinh thần vững chắc nhất, luôn tạo mọi điều kiện tốt nhất để em có thể yên tâm học tập và hoàn thành chương trình học của mình. Em xin chân thành cảm ơn!

Hà Nội, ngày 26 tháng 06 năm 2026

Sinh viên thực hiện

Nguyễn Thị Hương Giang

Tóm tắt nội dung

Đồ án này trình bày kết quả nghiên cứu và phát triển một hệ thống hỗ trợ chẩn đoán bệnh da liễu thông minh dựa trên học sâu đa phương thức. Hệ thống đã xây dựng thành công một pipeline xử lý ảnh y tế toàn diện, bắt đầu bằng việc nghiên cứu cơ sở lý thuyết về *Tensor*, mạng nơ-ron tích chập (*CNN*), cơ chế chú ý không gian-kênh (*CBAM*) và bản chất toán học của kỹ thuật thích ứng hạng thấp (*LoRA*) trên các mô hình ngôn ngữ lớn.

Về mặt kỹ thuật, đồ án đã phát triển mô-đun phân đoạn tổn thương da sử dụng mạng **DeepLabV3+** tích hợp kỹ thuật tăng cường đa tỷ lệ (*Multi-scale TTA*), cho phép bóc tách chính xác vùng quan tâm (*ROI*) ngay cả trong điều kiện nhiễu. Tiếp theo, một hệ thống phân loại **7 nhóm bệnh lý da liễu** đã được thiết kế dựa trên mạng **EfficientNet-B1** với cơ chế chú ý kép và mô hình hợp nhất Bayes (*Bayesian Late Fusion*), kết hợp hiệu quả đặc trưng hình ảnh với dữ liệu dịch tễ. Đặc biệt, đồ án đã triển khai trợ lý hội thoại y

khoa trực quan (*VQA*) dựa trên kiến trúc chứng cất tri thức cùng cơ chế truy xuất tri thức y văn hỗ trợ (*RAG*), nhằm minh bạch hóa các quyết định chẩn đoán.

Cuối cùng, toàn bộ hệ thống đã được hoàn thiện với quy trình xử lý ảnh y văn hỗ trợ chuẩn **DICOM**, tích hợp hệ thống lọc an toàn chất lượng ảnh (*Safety Gate*) và các thực nghiệm đánh giá định lượng chuyên sâu trên các tập dữ liệu ISIC 2018 và HAM10000 đã chứng minh hiệu năng vượt trội và tính ứng dụng cao trong môi trường lâm sàng.

Mục lục

Danh sách hình vẽ	vii
Danh sách bảng	viii
Ký hiệu và chữ viết tắt	ix
Mở đầu	1
Chương 1 Cơ sở lý thuyết & nền tảng kỹ thuật	4
1.1 Đại số tuyến tính và lý thuyết không gian Vector	4
1.1.1 Ma trận và các phép toán cơ bản	4
1.1.2 Biểu diễn Tensor của ảnh y tế	6
1.2 Cơ sở về học máy và các vấn đề tối ưu	7
1.2.1 Khái niệm cơ bản học máy	7
1.2.2 Vấn đề Overfitting và Underfitting	8
1.2.3 Mất cân bằng lớp (Class Imbalance)	10
1.3 Các thành phần cốt lõi của Mạng nơ-ron học sâu	11
1.3.1 Phép biến đổi Affine và lớp kết nối đầy đủ (Fully Connected)	11
1.3.2 Toán tử tích chập 2D và cơ chế tối ưu hóa im2col trên CPU	12
1.3.3 Hàm kích hoạt phi tuyến và chuẩn hóa lô (Batch Normalization)	13
1.3.4 Lý thuyết Học dư thừa (Residual Learning)	14
1.4 Kiến trúc thị giác máy tính và cơ chế chú ý	15
1.4.1 Kiến trúc xương sống EfficientNet-B1	15
1.4.2 Cơ chế chú ý tích hợp CBAM	15
1.4.3 Kiến trúc phân đoạn DeepLabV3+ và khối ASPP . . .	16
1.5 Kiến trúc xử lý ngôn ngữ và trợ lý VQA	18
1.5.1 Cơ chế tự chú ý (Self-Attention) và kiến trúc Transformer	18
1.5.2 Cơ sở toán học của kỹ thuật LoRA (Low-Rank Adaptation) trên mô hình ngôn ngữ	18
1.5.3 Tầng chiếu liên kết đa phương thức	19
1.5.4 Cơ chế truy xuất RAG dựa trên độ tương đồng Cosine	20

1.6	Các giải thuật hỗ trợ và chuẩn hóa y tế	20
1.6.1	Giải thích mô hình bằng thuật toán Grad-CAM	20
1.6.2	Phân tích độ sắc nét qua toán tử Laplacian và Hessian	21
1.6.3	Kiểm soát phơi sáng thích ứng và công bằng thuật toán	21
1.6.4	Mô hình hợp nhất đa phương thức Bayes	22
1.6.5	Giải thuật phân đoạn tương tác và cơ chế dự phòng an toàn	22
1.6.6	Xử lý tương thích định dạng dữ liệu y khoa DICOM .	23
1.7	Hàm mất mát và các tiêu chí đánh giá hệ thống	24
1.7.1	Các hàm mất mát (Dice, BCE, Combined Loss)	24
1.7.2	Các thước đo định lượng	26
Chương 2 Thiết kế hệ thống và xây dựng phương pháp		28
2.1	Khảo sát các phương pháp chẩn đoán bệnh da liễu hiện có . .	28
2.1.1	Phương pháp truyền thống và các giới hạn vật lý . . .	28
2.1.2	Sự phát triển của công nghệ chẩn đoán dựa trên hình ảnh số hóa	30
2.1.3	Kỷ nguyên học máy truyền thống và kỹ nghệ đặc trưng	32
2.1.4	Kỷ nguyên Học sâu trong Phân tích ảnh Da liễu . . .	33
2.2	Kết luận lựa chọn kiến trúc mô hình	34
2.2.1	Hệ thống Phân đoạn: Mạng DeepLabV3+ kết hợp Multi- Scale TTA	34
2.2.2	Hệ thống Phân loại: EfficientNet-B1 tích hợp Lớp chú ý CBAM	35
2.3	Kiến trúc tổng quan hệ thống và Luồng xử lý	35
2.3.1	Sơ đồ quy trình luồng xử lý dữ liệu tổng thể (Pipeline)	36
2.3.2	Vai trò toán học và chức năng chuyên biệt của các mô-đun	36
2.4	Bộ dữ liệu và Chiến lược tiền xử lý toán học	37
2.4.1	Phân tích cấu trúc các tập dữ liệu nguồn chuẩn hóa .	37
2.4.2	Quy trình chuẩn hóa toán học và Tăng cường dữ liệu .	38
2.5	Thiết kế giao diện ứng dụng và cơ sở dữ liệu Cloud Firestore .	39
2.5.1	Hệ thống giao diện Web y tế trực quan Streamlit . . .	39
2.5.2	Kiến trúc lưu trữ lại và quản lý định danh bệnh nhân	39
2.5.3	Tự động hóa báo cáo y khoa	40
2.6	Chiến lược xử lý mất cân bằng lớp chuyên sâu trong phân loại	40

2.6.1	Phân tích toán học định lượng về thực trạng chênh lệch dữ liệu	40
2.6.2	Thuật toán cân bằng không gian học tập đa tầng . . .	40
2.6.3	Đánh giá hiệu quả qua Macro F1-Score	41
2.7	Phương pháp hậu xử lý hình học và bộ lọc nhiễu thực tế . . .	41
2.7.1	Thuật toán lọc thành phần liên thông dựa trên chỉ số Solidity	41
2.7.2	Thiết kế cấu trúc mã nguồn và thực thể dữ liệu (ERD)	42
Chương 3 Thực nghiệm và kết quả định lượng		43
3.1	Thiết lập hệ thống thực nghiệm	43
3.1.1	Môi trường phần cứng và phần mềm học sâu	43
3.1.2	Phân tách dữ liệu qua phương pháp lấy mẫu phân tầng	44
3.2	Kết quả bài toán phân đoạn tổn thương ngữ nghĩa	45
3.2.1	Đánh giá kết quả định lượng và động học hội tụ	45
3.2.2	Phân tích hình thái học định tính	45
3.3	Kết quả bài toán phân loại danh mục bệnh lý da liễu	46
3.3.1	Hiệu năng tổng thể và Hàm mất mát có trọng số . . .	46
3.3.2	Lượng hóa chi tiết từng nhóm bệnh lý	46
3.4	Huấn luyện trợ lý hội thoại y khoa VQA	47
3.4.1	Thông số quy mô huấn luyện qua kỹ thuật LoRA . . .	47
3.4.2	Động học hội tụ sai số huấn luyện (Causal LM Loss) .	48
3.5	Phân tích hiệu năng tính toán và Nghiên cứu cắt bỏ	49
3.5.1	Benchmark thời gian đáp ứng và Chi phí tài nguyên .	49
3.5.2	Nghiên cứu cắt bỏ cấu trúc (Ablation Study)	50
3.6	Đánh giá tổng quát ưu điểm và giới hạn hệ thống	51
3.6.1	Các thể mạnh chiến lược	51
3.6.2	Các rào cản kỹ thuật và hướng khắc phục	51
Kết luận		52
Tài liệu tham khảo		54

Danh sách hình vẽ

1.1	Tiến trình biến đổi không gian Tensor từ dữ liệu pixel thô sang không gian ngữ nghĩa cao tầng.	7
1.2	Sơ đồ tối ưu hóa luồng dữ liệu tích chập bằng giải thuật im2col trên kiến trúc CPU.	13
1.3	Sơ đồ kiến trúc chú ý kép tuần tự của Module CBAM.	16
1.4	Kiến trúc đa luồng của khối ASPP giúp khai thác ngữ cảnh đa thang đo trong phân đoạn ảnh.	18
1.5	Quy trình căn chỉnh không gian đặc trưng đa phương thức thông qua tầng chiếu MLP tuyến tính.	20
2.1	Sơ đồ luồng xử lý dữ liệu tuần tự và kiến trúc phân lớp của hệ thống.	36
2.2	Sơ đồ thực thể quan hệ (ERD) mô tả cấu trúc lưu trữ dữ liệu y tế trên Cloud Firestore.	42
3.1	Biểu đồ tròn thể hiện tính cân đối trong phân chia tập dữ liệu huấn luyện/kiểm tra.	45
3.2	Động học hội tụ hàm mất mát Causal LM Loss của mô hình VQA (DistilGPT-2 + LoRA).	49
3.3	Biểu đồ phân rã chi phí thời gian thực thi của từng mô-đun trong toàn bộ Pipeline hệ thống.	50

Danh sách bảng

1.1	Các phép biến đổi dữ liệu phổ biến trong xử lý ảnh y tế [38]. .	10
1.2	Phân phối các lớp tổn thương da trong tập dữ liệu HAM10000.	10
2.1	Phân phối chi tiết các lớp bệnh lý trong tập dữ liệu HAM10000.	38
3.1	Cấu hình chi tiết hệ thống phần cứng và phần mềm thực nghiệm.	44
3.2	Phân bổ quy mô số lượng mẫu chi tiết cho các tập dữ liệu thực nghiệm.	44
3.3	Đối chứng hiệu năng phân đoạn trên tập kiểm thử ISIC 2018.	45
3.4	Báo cáo chi tiết hiệu năng phân loại.	47
3.5	So sánh đo lường thời gian suy luận trung bình giữa các kiến trúc.	49
3.6	Kết quả thực nghiệm nghiên cứu cắt bỏ các mô-đun cấu trúc hệ thống.	50

Ký hiệu và chữ viết tắt

AI	Trí tuệ nhân tạo	IoU	Chỉ số Giao trên Hợp
AKIEC	Dày sừng ánh sáng	ISIC	Tổ chức Hình ảnh da quốc tế
ASPP	Tích chập đa tỷ lệ	MEL	Ung thư hắc tố
BCC	Ung thư biểu mô tế bào đáy	NV	Nốt ruồi hắc tố
BKL	Dày sừng lành tính	ROI	Vùng quan tâm
CBAM	Mô-đun chú ý khối tích chập	SAM	Mô-đun chú ý không gian
CNN	Mạng nơ-ron tích chập	VASC	Tổn thương mạch máu
DF	Xơ da liễu	GT	Nhãn chuẩn (Ground Truth)
Dice	Chỉ số tương đồng Dice	LR	Tốc độ học

Mở đầu

Trong những thập kỷ gần đây, ung thư da đã trở thành một trong những gánh nặng y tế lớn nhất trên toàn cầu với số lượng ca mắc mới tăng lên một cách báo động. Theo các nghiên cứu dịch tễ học, việc phát hiện sớm và chẩn đoán chính xác các tổn thương da, đặc biệt là u hắc tố ác tính (Melanoma), đóng vai trò quyết định đến tỷ lệ sống sót của bệnh nhân. Nếu được can thiệp kịp thời ở giai đoạn khu trú, tỷ lệ điều trị thành công có thể lên tới trên 95% [12, 44].

Tuy nhiên, thực trạng chẩn đoán da liễu hiện nay vẫn đối mặt với nhiều thách thức lớn:

- **Tính chủ quan và sai số chẩn đoán:** Quy trình đánh giá hình thái học phụ thuộc nặng nề vào kinh nghiệm của bác sĩ lâm sàng, dẫn đến sự thiếu nhất quán trong việc phân biệt ranh giới giữa tổn thương lành tính và ác tính [21].
- **Sự khan hiếm nguồn lực chuyên gia:** Sự thiếu hụt các chuyên gia da liễu trình độ cao tại các cơ sở y tế tuyến dưới gây ra tình trạng quá tải và chậm trễ trong sàng lọc bệnh lý.
- **Rào cản về công nghệ:** Các hệ thống chẩn đoán truyền thống dựa trên kỹ nghệ đặc trưng thủ công (*Hand-crafted features*) không đủ khả năng mô hình hóa sự đa dạng và phức tạp của các biểu hiện bệnh lý trên dữ liệu ảnh thực tế.

Sự bùng nổ của học sâu (*Deep Learning*), đặc biệt là sau các cột mốc quan trọng của mạng nơ-ron tích chập (CNN), đã thay đổi hoàn toàn diện mạo của y tế số [22]. Khác với các phương pháp cũ, học sâu cho phép hệ thống tự động trích xuất các đặc trưng phân cấp từ dữ liệu ảnh thô, giúp đạt được độ chính xác tiệm cận chuyên gia. Trong lĩnh vực da liễu, mặc dù các kiến trúc như U-Net [34] hay DeepLabV3+ [6] đã tạo ra những đột phá trong bài toán

phân đoạn, việc ứng dụng chúng vào môi trường lâm sàng vẫn gặp phải các rào cản kỹ thuật:

- **Sự suy giảm hiệu năng do nhiễu vật lý:** Các tác nhân như lông, nếp gấp da và điều kiện ánh sáng không đồng nhất làm nhiễu loạn phân phối xác suất của mô hình.
- **Hạn chế về tính giải thích:** Bản chất "hộp đen" của AI khiến các y bác sĩ khó tin tưởng vào kết quả nếu không có các bằng chứng thị giác và tri thức y văn hỗ trợ.
- **Sự tách rời giữa hình ảnh và bệnh sử:** Các mô hình hiện nay thường chỉ tập trung vào ảnh soi da mà bỏ qua các yếu tố dịch tễ quan trọng như tuổi, giới tính và vị trí tổn thương.

Do đó, đề án đề xuất đề tài: **“Nghiên cứu và xây dựng hệ thống phân tích đa phương thức hỗ trợ chẩn đoán bệnh da liễu tích hợp hỏi đáp trực quan y tế”**. Hệ thống hướng tới việc kết hợp sức mạnh của thị giác máy tính hiện đại và mô hình ngôn ngữ lớn để tạo ra một giải pháp hỗ trợ quyết định lâm sàng toàn diện.

Đề án hướng tới các mục tiêu cụ thể sau:

- Xây dựng quy trình xử lý ảnh y tế hoàn chỉnh từ khâu giải mã DICOM, đánh giá chất lượng ảnh đến chẩn đoán bệnh lý.
- Phát triển mô hình phân đoạn kết hợp ứng dụng kỹ thuật TTA đa tỷ lệ để trích xuất chính xác vùng quan tâm.
- Thiết kế mạng phân loại dựa trên EfficientNet-B1 tích hợp cơ chế chú ý CBAM và mô hình hợp nhất Bayes để kết hợp thông tin hình ảnh và dịch tễ học.
- Triển khai trợ lý hỏi đáp trực quan (VQA) dựa trên kỹ thuật LoRA và cơ chế RAG để cung cấp giải thích y khoa dựa trên tri thức y văn chuẩn hóa.

Đối tượng nghiên cứu:

- Hình ảnh soi da và mặt nạ chuẩn từ tập dữ liệu quốc tế ISIC 2018 (Task 1).

- Tập dữ liệu HAM10000 bao gồm 10.015 ảnh đã được gán nhãn cho 7 nhóm bệnh lý da liễu.
- Tri thức y văn và các câu hỏi lâm sàng phục vụ huấn luyện mô hình VQA y tế.

Phương pháp nghiên cứu:

- **Lý thuyết:** Nghiên cứu các toán tử tích chập Atrous, cơ chế chú ý không gian-kênh, lý thuyết xác suất Bayes và kiến trúc Transformer hạng thấp (LoRA).
- **Thực nghiệm:** Huấn luyện và tối ưu hóa mô hình bằng thư viện PyTorch trên hạ tầng GPU; tối ưu hóa suy luận (Inference) để vận hành ổn định trên CPU.
- **Đánh giá:** Sử dụng các chỉ số Dice, IoU, Macro F1-score và BLEU để định lượng hiệu năng của hệ thống đa nhiệm.

Nội dung đồ án được chia làm 3 chương chính:

- **Chương 1: Cơ sở lý thuyết & nền tảng kỹ thuật:** Trình bày lý thuyết về Tensor, mạng CNN, các cơ chế chú ý CBAM, tích chập Atrous và bản chất toán học của kỹ thuật LoRA trên LLM.
- **Chương 2: Thiết kế hệ thống và xây dựng phương pháp:** Chi tiết hóa kiến trúc Pipeline đa tầng, giải thuật hợp nhất Bayes, cơ chế RAG y khoa và sơ đồ thực thể dữ liệu trên Cloud Firestore.
- **Chương 3: Thực nghiệm và Kết quả định lượng:** Trình bày các kết quả đạt được, phân tích nghiên cứu cắt bỏ (Ablation Study), đánh giá thời gian thực thi và thảo luận về các ưu điểm, hạn chế của hệ thống.

Chương 1

Cơ sở lý thuyết & nền tảng kỹ thuật

1.1 Đại số tuyến tính và lý thuyết không gian Vector

1.1.1 Ma trận và các phép toán cơ bản

a) Định nghĩa ma trận

Định nghĩa 1.1 Giả sử $\mathbb{K}$ là một trường tùy ý.

Ma trận có dạng

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix},$$

trong đó $a_{ij} \in \mathbb{K}$ ($1 \leq i \leq m, 1 \leq j \leq n$), được gọi là một ma trận m hàng (hay dòng) n cột với các phần tử trong $\mathbb{K}$. Nếu $m = n$, thì ta nói A là một ma trận vuông cấp n .

Vectơ hàng

$$(a_{i1}, a_{i2}, \cdots, a_{in})$$

được gọi là hàng thứ i của ma trận A .

Vectơ cột

$$(a_{1j}, a_{2j}, \cdots, a_{mj})^t$$

được gọi là cột thứ j của ma trận A .

Ký hiệu là $A_{m \times n}$ hoặc $A = (a_{ij})_{m \times n}$ [42].

b) Phép cộng và nhân ma trận vô hướng

Đây là các phép toán thực hiện trên từng phần tử (element-wise), định nghĩa cấu trúc không gian vectơ cho tập hợp các ma trận.

Phép cộng: Cho $A, B \in M(m \times n, \mathbb{K})$, ma trận tổng $C = A + B$ có các phần tử:

$$c_{ij} = a_{ij} + b_{ij}, \quad \forall i, j$$

Phép nhân với vô hướng: Cho $A \in M(m \times n, \mathbb{K})$ và $\alpha \in \mathbb{K}$, ma trận $D = \alpha A$ có các phần tử:

$$d_{ij} = \alpha a_{ij}, \quad \forall i, j$$

Trong học sâu, các phép toán này được sử dụng khi cập nhật trọng số mạng hoặc khi thực hiện các phép biến đổi chuẩn hóa dữ liệu ảnh [14].

c) Phép nhân ma trận

Phép nhân hai ma trận A và B chỉ thực hiện được khi số cột của ma trận A bằng số hàng của ma trận B [42].

Tích AB của ma trận $A = (a_{ij})_{m \times n}$ và ma trận $B = (b_{jk})_{n \times p}$ là ma trận $C = (c_{ik}) \in M(m \times p, \mathbb{K})$ với các phần tử được xác định như sau:

$$c_{ik} = \sum_{j=1}^n a_{ij} b_{jk}, \quad (1 \leq i \leq m, 1 \leq k \leq p).$$

d) Ma trận chuyển vị

Định nghĩa 1.2 Ma trận chuyển vị của A (ký hiệu A^T) là ma trận thu được bằng cách hoán đổi các hàng thành các cột và các cột thành các hàng của A .

- **Ký hiệu:** Nếu A là ma trận $m \times n$, thì A^T là ma trận $n \times m$.

$$(A^T)_{i,j} = A_{j,i}$$

Phép chuyển vị ma trận là một phép toán cơ bản trong đại số tuyến tính [42].

e) Ma trận nghịch đảo

Định nghĩa 1.3 Ma trận $A \in M(n \times n, \mathbb{K})$ được gọi là một ma trận khả nghịch (hoặc ma trận không suy biến) nếu có ma trận $B \in M(n \times n, \mathbb{K})$ sao cho $AB = BA = E_n$. Khi đó, ta nói B là nghịch đảo của A và ký hiệu $B = A^{-1}$ [42]. Với E_n là phần tử đơn vị của vành $M(n \times n, \mathbb{K})$, được định

nghĩa là ma trận sau đây:

$$E = E_n = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix}.$$


1.1.2 Biểu diễn Tensor của ảnh y tế

Trong lĩnh vực thị giác máy tính dành cho chẩn đoán hình ảnh y văn và nội soi lâm sàng, một thực thể hình ảnh kỹ thuật số không chỉ đơn thuần là tập hợp các điểm ảnh, mà được mô hình hóa toán học như một phần tử nằm trong không gian tensor thực ba chiều[14]:

$$\mathbf{X} \in \mathbb{R}^{H \times W \times C} \quad (1.1)$$

Trong đó, $H \in \mathbb{N}$ đại diện cho chiều cao không gian (số lượng pixel theo hàng), $W \in \mathbb{N}$ đại diện cho chiều rộng không gian (số lượng pixel theo cột), và $C \in \mathbb{N}$ là số lượng kênh đặc trưng (*feature channels*). Tại tầng cảm biến đầu vào, $C = 3$ tương ứng với không gian màu RGB, biểu diễn cường độ ánh sáng tại ba bước sóng Đỏ (Red), Lục (Green), và Lam (Blue) dưới dạng các hàm rời rạc của tọa độ không gian.

Trong kiến trúc mạng nơ-ron tích chập sâu (DCNN) của hệ thống, dữ liệu $\mathbf{X}$ trải qua một chuỗi các phép biến đổi phi tuyến liên tục. Tại các tầng ẩn sâu nhất, tensor $\mathbf{X}$ được ánh xạ sang không gian đặc trưng tiềm ẩn (*latent space*) $\mathbf{H} \in \mathbb{R}^{H' \times W' \times D}$. Theo cấu trúc của Backbone EfficientNet-B1 được triển khai[43], chiều sâu đặc trưng D được mở rộng lên 1280 chiều. Đây là kết quả của quá trình phân rã đa tuyến tính, giúp tách biệt các tín hiệu hình thái học phức tạp khỏi nhiễu nền. Độ phân giải không gian $H' \times W'$ được nén xuống mức 7×7 thông qua các toán tử Downsampling, đảm bảo tính bất biến tịnh tiến và tập trung tối đa vào các đặc trưng ngữ nghĩa phục vụ phân loại bệnh lý.



Hình 1.1: Tiến trình biến đổi không gian Tensor từ dữ liệu pixel thô sang không gian ngữ nghĩa cao tầng.

1.2 Cơ sở về học máy và các vấn đề tối ưu

1.2.1 Khái niệm cơ bản học máy

Định nghĩa 1.4 Học máy (Machine Learning) là một lĩnh vực của trí tuệ nhân tạo nghiên cứu các thuật toán cho phép máy tính "học" từ dữ liệu để thực hiện nhiệm vụ cụ thể mà không cần được lập trình tường minh cho từng trường hợp [25].

Phân loại:

- *Supervised Learning* (Học có giám sát): Mô hình học từ dữ liệu **có nhãn** (labeled data), tức là mỗi mẫu đầu vào đi kèm với đầu ra đúng.
- *Unsupervised Learning* (Học không giám sát): Mô hình học từ dữ liệu **không có nhãn**, tìm cấu trúc ẩn trong dữ liệu.
- *Semi-supervised Learning* (Học bán giám sát): Kết hợp giữa supervised và unsupervised learning, sử dụng một phần dữ liệu có nhãn và phần lớn dữ liệu không nhãn.
- *Reinforcement Learning* (Học tăng cường): Agent (tác nhân) học cách hành động trong môi trường bằng cách tối đa hóa *reward* (phần thưởng) tích lũy.

Quy trình huấn luyện:

Để đánh giá khách quan hiệu năng của mô hình và tránh overfitting, dữ liệu được chia thành ba tập riêng biệt [14]:

- *Training Set* (Tập huấn luyện): Dùng để học (optimize) tham số của mô hình.

- *Validation Set* (Tập kiểm chứng): Dùng để điều chỉnh hyperparameters và theo dõi overfitting.
- *Test Set* (Tập kiểm tra): Đánh giá khách quan hiệu năng của mô hình trên dữ liệu chưa từng thấy.

1.2.2 Vấn đề Overfitting và Underfitting

a) Định nghĩa

Định nghĩa 1.5 Trong quá trình huấn luyện mạng nơ-ron, sự cân bằng giữa khả năng học tập và khả năng tổng quát hóa là yếu tố then chốt:

- **Overfitting (Quá khớp):** Xảy ra khi mô hình học quá chi tiết trên tập huấn luyện, bao gồm cả các nhiễu (*noise*) và các biến động ngẫu nhiên không mang tính quy luật. Hệ quả là mô hình đạt độ chính xác cực cao trên tập huấn luyện nhưng thực hiện rất kém trên dữ liệu mới chưa từng thấy (dữ liệu kiểm tra) do mất đi tính tổng quát hóa [14].
- **Underfitting (Dưới khớp):** Xảy ra khi mô hình quá đơn giản hoặc chưa được huấn luyện đủ, dẫn đến không thể học được các quy luật cơ bản (*patterns*) của dữ liệu, gây hiệu năng kém trên cả tập huấn luyện lẫn tập kiểm tra [14].

b) Nguyên nhân

Nguyên nhân gây Overfitting:

- **Độ phức tạp của mô hình:** Số lượng tham số quá lớn so với kích thước và sự đa dạng của tập dữ liệu.
- **Dữ liệu huấn luyện hạn chế:** Tập dữ liệu không đủ đại diện cho toàn bộ phân phối thực tế.
- **Thời gian huấn luyện quá dài:** Sau khi đạt điểm tối ưu, việc tiếp tục huấn luyện khiến mô hình bắt đầu "học thuộc lòng" dữ liệu.
- **Thiếu cơ chế điều chuẩn:** Không sử dụng các phương pháp ràng buộc độ phức tạp của trọng số.

Nguyên nhân gây Underfitting:

- **Mô hình thiếu năng lực (*Capacity*):** Kiến trúc mạng quá nông hoặc quá ít nơ-ron để biểu diễn các hàm phi tuyến phức tạp.
- **Đặc trưng không phù hợp:** Các tín hiệu đầu vào không chứa đủ thông tin để phân biệt các lớp dữ liệu.
- **Huấn luyện chưa tới hạn:** Quá trình tối ưu hóa bị dừng quá sớm hoặc tốc độ học không phù hợp khiến mô hình chưa hội tụ.

c) Giải pháp

Giải pháp cho Overfitting:

- **Điều chuẩn L2 (Weight Decay):** Thêm thành phần phạt vào hàm mất mát để kiểm soát độ lớn của trọng số nhằm ưu tiên các mô hình đơn giản hơn [14]:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{data}} + \lambda \sum_i w_i^2$$

- **Dropout:** Trong quá trình huấn luyện, ngẫu nhiên "tắt" một tỷ lệ neurons với xác suất p để buộc mạng học các đặc trưng mạnh mẽ và độc lập hơn [40]. Công thức cho một tầng có kích hoạt $\mathbf{z}$:

$$\mathbf{h} = \text{Dropout}(\mathbf{z}, p) = \mathbf{z} \odot \mathbf{m}$$

với $\mathbf{m}$ là vector mặt nạ nhị phân tuân theo $P(m_i = 1) = 1 - p$.

- **Dừng sớm (Early Stopping):** Theo dõi sai số trên tập kiểm chứng và dừng huấn luyện khi hiệu năng không còn được cải thiện để ngăn chặn việc học quá mức [31].
- **Tăng cường dữ liệu (Data Augmentation):** Tạo thêm dữ liệu huấn luyện bằng cách áp dụng các phép biến đổi lên dữ liệu gốc mà không làm thay đổi nhãn của chúng [38].

Bảng 1.1: Các phép biến đổi dữ liệu phổ biến trong xử lý ảnh y tế [38].

Phép biến đổi	Mô tả	Ví dụ
Horizontal Flip	Lật ảnh theo trục ngang	Tổn thương bên trái $\rightarrow$ bên phải
Vertical Flip	Lật ảnh theo trục dọc	Tổn thương bên trên $\rightarrow$ bên dưới
Rotation	Xoay góc ngẫu nhiên	Xoay trong khoảng $\pm 15^\circ$
Brightness	Điều chỉnh cường độ sáng	Giả lập điều kiện ánh sáng $\pm 20\%$
Gaussian Noise	Thêm nhiễu trắng	Tăng tính bền vững với $\sigma = 0.01$
Cutout	Che khuất ngẫu nhiên	Che một vùng 16×16 pixels

- **Batch Normalization:** Chuẩn hóa đầu ra của mỗi tầng về phân phối chuẩn để ổn định quá trình huấn luyện. Công thức thực hiện cho một batch B :

1. Mean và variance: $\mu_B = \frac{1}{B} \sum \mathbf{x}_i, \sigma_B^2 = \frac{1}{B} \sum (\mathbf{x}_i - \mu_B)^2$
2. Chuẩn hóa: $\hat{\mathbf{x}}_i = \frac{\mathbf{x}_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$
3. Scale và shift: $\mathbf{y}_i = \gamma \hat{\mathbf{x}}_i + \beta$

1.2.3 Mất cân bằng lớp (Class Imbalance)

a) Vấn đề trong dữ liệu y tế

Hiện tượng mất cân bằng lớp xảy ra khi các lớp trong tập dữ liệu có số lượng mẫu không đồng đều, gây khó khăn cho việc huấn luyện mô hình chẩn đoán chính xác.

Bảng 1.2: Phân phối các lớp tổn thương da trong tập dữ liệu HAM10000.

Lớp	Tên đầy đủ	Số ảnh	Tỷ lệ	Trọng số
NV	Melanocytic nevi	6,705	67.0%	0.21
MEL	Melanoma	1,113	11.1%	1.29
BKL	Benign keratosis	1,099	11.0%	1.31
BCC	Basal cell carcinoma	514	5.1%	2.80
AKIEC	Actinic keratoses	327	3.3%	4.40
VASC	Vascular lesions	142	1.4%	10.13
DF	Dermatofibroma	115	1.1%	12.51

Hậu quả:

1. **Thiên kiến mô hình:** Mô hình có xu hướng ưu tiên dự đoán lớp đa số (NV) để tối ưu độ chính xác tổng thể.

2. **Bỏ sót bệnh lý:** Các lớp thiểu số nhưng có ý nghĩa y tế cao (như Melanoma) dễ bị bỏ sót.
3. **Độ chính xác giả tạo:** Accuracy cao không phản ánh đúng hiệu năng thực tế trên các lớp hiếm.

b) Giải pháp

- **Hàm mất mát có trọng số (Weighted Cross-Entropy):** Gán trọng số cao hơn cho các mẫu thuộc lớp hiếm trong hàm mất mát để mô hình tập trung hơn vào chúng [14]:

$$\mathcal{L}_{\text{WCE}} = - \sum_{i=1}^K w_i \cdot y_i \log(\hat{y}_i)$$

Trọng số lớp w_k tính theo nghịch đảo tần suất: $w_k = \frac{N}{K \cdot n_k}$.

- **Focal Loss:** Giảm đóng góp của các mẫu dễ phân loại và tập trung vào các mẫu khó (*hard examples*):

$$\mathcal{L}_{\text{FL}} = -\alpha_t (1 - p_t)^\gamma \log(p_t)$$

Trong đó $(1 - p_t)^\gamma$ là thành phần điều chỉnh giúp giảm mất mát cho các mẫu mô hình đã dự đoán đúng với độ tự tin cao.

- **Chiến lược lấy mẫu và tăng cường:**
 1. **Oversampling:** Lặp lại mẫu của lớp thiểu số hoặc áp dụng augmentation mạnh hơn cho chúng.
 2. **Undersampling:** Giảm bớt số lượng mẫu của lớp đa số.
 3. **Hybrid:** Kết hợp cả hai phương pháp trên để cân bằng tập dữ liệu.

1.3 Các thành phần cốt lõi của Mạng nơ-ron học sâu

1.3.1 Phép biến đổi Affine và lớp kết nối đầy đủ (Fully Connected)

Lớp tuyến tính (FC) đóng vai trò là bộ phân loại cuối cùng, thực hiện phép ánh xạ Affine giữa hai không gian vector Euclid hữu hạn chiều $\mathcal{T} : \mathbb{R}^{d_{\text{in}}} \rightarrow \mathbb{R}^{d_{\text{out}}}$. Biểu thức toán học của quá trình truyền xuôi được xác định bởi [36]:

$$\mathbf{y} = \mathbf{W}\mathbf{x} + \mathbf{b} \tag{1.2}$$

Trong đó:

- $\mathbf{x} \in \mathbb{R}^{d_{\text{in}}}$ là vector đặc trưng đầu vào (thường là kết quả của phép toán Global Average Pooling).
- $\mathbf{W} \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$ là ma trận trọng số, chứa đựng các hệ số học tập đại diện cho các siêu phẳng phân cách trong không gian đặc trưng.
- $\mathbf{b} \in \mathbb{R}^{d_{\text{out}}}$ là vector chệch (*bias vector*), cho phép dịch chuyển hệ tọa độ để tối ưu hóa ranh giới quyết định.

Từng thành phần y_i của vector đầu ra được tính toán thông qua tích vô hướng giữa hàng thứ i của ma trận trọng số và vector đầu vào:

$$y_i = \sum_{j=1}^{d_{\text{in}}} W_{i,j} x_j + b_i \quad (1.3)$$

Để cập nhật trọng số trong quá trình huấn luyện, ta sử dụng thuật toán lan truyền ngược. Đạo hàm của hàm mất mát L đối với các tham số được tính toán nghiêm ngặt theo quy tắc chuỗi[22]:

$$\frac{\partial L}{\partial \mathbf{W}} = \left(\frac{\partial L}{\partial \mathbf{y}} \right) \mathbf{x}^T \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}} \quad (1.4)$$

$$\frac{\partial L}{\partial \mathbf{x}} = \mathbf{W}^T \left(\frac{\partial L}{\partial \mathbf{y}} \right) \in \mathbb{R}^{d_{\text{in}}} \quad (1.5)$$

Phép toán này đảm bảo rằng độ dốc lỗi được truyền ngược chính xác từ đầu ra về phía đầu vào, cho phép mô hình tự điều chỉnh cấu trúc ma trận để cực tiểu hóa sai số dự báo.

1.3.2 Toán tử tích chập 2D và cơ chế tối ưu hóa im2col trên CPU

Phép tích chập hai chiều là hạt nhân của quá trình trích xuất đặc trưng không gian. Cho một tensor $\mathbf{X} \in \mathbb{R}^{H \times W \times C_{\text{in}}}$ và tập hợp bộ lọc $\mathbf{K} \in \mathbb{R}^{k \times k \times C_{\text{in}} \times C_{\text{out}}}$, giá trị tại tọa độ (i, j) trên kênh đầu ra o được xác định bởi công thức vi phân rời rạc:


$$Y(i, j, o) = \sum_{c=0}^{C_{\text{in}}-1} \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} X(i \cdot s + m, j \cdot s + n, c) \cdot K(m, n, c, o) + b(o) \quad (1.6)$$

Trong đó k là kích thước kernel (thường là 3×3), s là bước nhảy (*stride*).

Nhằm đáp ứng yêu cầu thực thi thời gian thực trên các hệ thống y tế sử dụng CPU (không có hỗ trợ GPU chuyên dụng), hệ thống sử dụng kỹ thuật

tối ưu hóa thông qua giải thuật `im2col` (Image to Column)[5]. Giải thuật này chuyển đổi bài toán cửa sổ trượt (vốn có độ phức tạp truy cập bộ nhớ cao) thành phép nhân ma trận khối (*GEMM* - *General Matrix Multiply*), tận dụng tối đa sức mạnh của tập lệnh vector hóa AVX-512[9]:

1. **Biến đổi `im2col`:** Mỗi vùng không gian $k \times k \times C_{in}$ được duỗi phẳng (*flatten*) thành một vector cột có kích thước $d_{col} = k^2 \cdot C_{in}$. Toàn bộ ảnh đầu vào được tái cấu trúc thành ma trận $\mathbf{X}_{col} \in \mathbb{R}^{(k^2 \cdot C_{in}) \times (H_{out} \cdot W_{out})}$.
2. **Ma trận hóa Kernel:** Các bộ lọc $\mathbf{K}$ được định hình lại thành ma trận $\mathbf{K}_{flat} \in \mathbb{R}^{C_{out} \times (k^2 \cdot C_{in})}$.
3. **Thực thi GEMM:** Tensor đầu ra được tính toán song song cực nhanh:
 $\mathbf{Y}_{col} = \mathbf{K}_{flat} \times \mathbf{X}_{col}$. Cuối cùng, kết quả được **reshape** về dạng $\mathbb{R}^{H_{out} \times W_{out} \times C_{out}}$.



Hình 1.2: Sơ đồ tối ưu hóa luồng dữ liệu tích chập bằng giải thuật `im2col` trên kiến trúc CPU.

1.3.3 Hàm kích hoạt phi tuyến và chuẩn hóa lô (Batch Normalization)

Tính phi tuyến là yếu tố then chốt giúp mạng nơ-ron có khả năng xấp xỉ các hàm số phức tạp trong phân loại bệnh lý da liễu.

- **Hàm ReLU (Rectified Linear Unit):** Được áp dụng trong các khối Attention CBAM để tạo tính thưa (*sparsity*) cho các bản đồ kích hoạt[28]:

$$\text{ReLU}(x) = \max(0, x) \quad (1.7)$$

- **Hàm SiLU (Sigmoid Linear Unit / Swish):** Là hàm kích hoạt chủ đạo trong Backbone EfficientNet-B1, giúp tránh hiện tượng "chết nơ-ron" và duy trì độ dốc ổn định[33]:

$$\text{SiLU}(x) = x \cdot \sigma(x) = \frac{x}{1 + e^{-x}} \quad (1.8)$$

- **Hàm GELU (Gaussian Error Linear Unit):** Được sử dụng trong thành phần Transformer của mô hình VQA V3 nhằm xử lý các mô tả lâm sàng. GELU kết hợp tính chất của ReLU và Dropout bằng cách trọng số hóa đầu vào theo hàm phân phối tích lũy của phân phối chuẩn tắc[18]:

$$\text{GELU}(x) = x\Phi(x) = x \cdot \frac{1}{2} \left[1 + \text{erf} \left(\frac{x}{\sqrt{2}} \right) \right] \quad (1.9)$$

Trong đó, hàm lỗi erf(z) được định nghĩa tích phân:

$$\text{erf}(z) = \frac{2}{\sqrt{\pi}} \int_0^z e^{-t^2} dt \quad (1.10)$$

- **Batch Normalization (BN):** Để kiểm soát hiện tượng dịch chuyển đồng biến nội bộ[20], mỗi mini-batch $B = \{x_1, \dots, x_m\}$ được chuẩn hóa về phân phối chuẩn đơn vị trước khi thực hiện phép ánh xạ học tập γ, β :

$$\mu_B = \frac{1}{m} \sum_{i=1}^m x_i, \quad \sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2, \quad y_i = \gamma \left(\frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \right) + \beta \quad (1.11)$$

1.3.4 Lý thuyết Học dư thừa (Residual Learning)

Trong các mạng nơ-ron tích chập truyền thống, việc tăng độ sâu của mạng thường dẫn đến hiện tượng tiêu biến đạo hàm (*vanishing gradient*), khiến sai số huấn luyện bị bão hòa và tăng cao. Để giải quyết vấn đề này, kiến trúc ResNet (được sử dụng làm xương sống ResNet50 trong hệ thống) giới thiệu cơ chế học dư thừa [17].

Giả sử mạng cần học một ánh xạ tối ưu là $H(\mathbf{x})$. Thay vì ép các tầng tích chập trực tiếp xấp xỉ $H(\mathbf{x})$, chúng được thiết kế để học hàm dư thừa:

$$\mathcal{F}(\mathbf{x}) = H(\mathbf{x}) - \mathbf{x} \quad (1.12)$$

Khi đó, ánh xạ gốc được tái cấu trúc thông qua một kết nối tắt (*shortcut connection* hoặc *skip connection*):

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x} \quad (1.13)$$

Toán tử cộng $\mathbf{x}$ ở đây được thực hiện theo từng phần tử (*element-wise addition*). Nếu kích thước không gian của $\mathcal{F}(\mathbf{x})$ và $\mathbf{x}$ khác nhau, một ma trận chiếu W_s sẽ được áp dụng để căn chỉnh số chiều: $\mathbf{y} = \mathcal{F}(\mathbf{x}) + W_s \mathbf{x}$.

Ý nghĩa toán học: Trong quá trình lan truyền ngược, đạo hàm $\frac{\partial \mathcal{L}}{\partial \mathbf{x}}$ luôn chứa thành phần $\frac{\partial \mathbf{x}}{\partial \mathbf{x}} = 1$. Điều này đảm bảo dòng chảy đạo hàm luôn được duy trì xuyên suốt các tầng sâu của mạng, cho phép mô hình hội tụ nhanh hơn và đạt độ chính xác cao hơn trên tập dữ liệu ảnh đa chiều phức tạp.

1.4 Kiến trúc thị giác máy tính và cơ chế chú ý

1.4.1 Kiến trúc xương sống EfficientNet-B1

Mô hình đề xuất sử dụng EfficientNet-B1 làm mạng xương sống (*Backbone*) nhằm tối ưu hóa sự cân bằng giữa độ chính xác phân loại và chi phí tài nguyên tính toán trên CPU. Khác với các kiến trúc truyền thống thường mở rộng mạng một cách cảm tính, EfficientNet thực thi nguyên lý tỷ lệ phức hợp (*Compound Scaling*)[43], điều chỉnh đồng thời cả ba chiều của mạng: chiều sâu (d), chiều rộng (w), và độ phân giải (r) thông qua một hệ số tỷ lệ đồng nhất $\phi \in \mathbb{R}$:

$$d = \alpha^\phi, \quad w = \beta^\phi, \quad r = \gamma^\phi \quad (1.14)$$

Với các hằng số cơ sở $\alpha, \beta, \gamma \geq 1$ được xác định qua tìm kiếm cấu trúc mạng, tuân theo ràng buộc về chi phí tính toán:

$$\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \quad (1.15)$$


Ràng buộc này xuất phát từ bản chất của toán tử tích chập: khi chiều sâu d tăng gấp đôi, tổng lượng tính toán (FLOPS) tăng tỉ lệ thuận (2^1), nhưng khi chiều rộng w hoặc độ phân giải r tăng gấp đôi, FLOPS sẽ tăng tỉ lệ thuận với lũy thừa bậc hai ($2^2 = 4$). Việc áp dụng EfficientNet-B1 cho phép mô hình trích xuất đặc trưng đa mức với 1280 kênh tại tầng cuối

1.4.2 Cơ chế chú ý tích hợp CBAM

Nhằm tinh lọc các đặc trưng quan trọng và loại bỏ nhiễu từ nền ảnh nội soi, một module CBAM được tích hợp sau backbone[46]. CBAM thực hiện tuần tự hai cơ chế chú ý hỗ trợ: chú ý theo trục kênh ($\mathbf{M}_c$) để xác định "cái gì" là quan trọng, và chú ý theo không gian ($\mathbf{M}_s$) để xác định "ở đâu" là trọng tâm:

$$\mathbf{F}' = \mathbf{M}_c(\mathbf{F}) \otimes \mathbf{F}, \quad \mathbf{F}'' = \mathbf{M}_s(\mathbf{F}') \otimes \mathbf{F}' \quad (1.16)$$

Trong đó $\otimes$ biểu thị phép nhân Hadamard (phần tử với phần tử) và $\mathbf{F}$ là tensor đặc trưng trung gian.



Hình 1.3: Sơ đồ kiến trúc chú ý kép tuần tự của Module CBAM.

Module Chú ý kênh

Để tổng hợp thông tin không gian, module sử dụng đồng thời hai phép toán Pooling toàn cục. Tensor đầu ra của mỗi phép toán được dẫn qua một mạng Perceptron đa lớp (MLP) dùng chung trọng số để giảm thiểu số lượng tham số:

$$\mathbf{M}_c(\mathbf{F}) = \sigma(\mathbf{W}_2 \cdot \text{ReLU}(\mathbf{W}_1 \cdot \text{GAP}(\mathbf{F})) + \mathbf{W}_2 \cdot \text{ReLU}(\mathbf{W}_1 \cdot \text{GMP}(\mathbf{F}))) \quad (1.17)$$

Trong đó $\mathbf{W}_1 \in \mathbb{R}^{\frac{C}{16} \times C}$ và $\mathbf{W}_2 \in \mathbb{R}^{C \times \frac{C}{16}}$. Tỷ lệ giảm (*reduction ratio*) $r = 16$ được thiết lập nhằm cân bằng giữa khả năng biểu diễn và độ phức tạp tính toán, giúp mô hình tập trung vào các kênh chứa thông tin bệnh lý quan trọng nhất.

Module Chú ý không gian (Spatial Attention Module)

Sau khi tinh lọc kênh, module tập trung vào các vùng điểm ảnh có ý nghĩa bằng cách nén tensor dọc theo trục kênh (Channel-wise pooling) và áp dụng một bộ lọc tích chập kích thước lớn 7×7 :

$$\mathbf{M}_s(\mathbf{F}') = \sigma(f^{7 \times 7}([\text{AvgPool}_c(\mathbf{F}'); \text{MaxPool}_c(\mathbf{F}')])) \quad (1.18)$$

Phép toán này tạo ra một bản đồ trọng số không gian, giúp nhấn mạnh các ranh giới tổn thương và loại bỏ các vùng nhiễu trắng thường gặp trong ảnh nội soi da liễu.

1.4.3 Kiến trúc phân đoạn DeepLabV3+ và khối ASPP

Toán tử tích chập Atrous

Toán tử tích chập Atrous (còn gọi là tích chập giãn nở) là công cụ then chốt trong phân đoạn hình ảnh, cho phép mở rộng trường cảm nhận mà không làm mất mát độ phân giải không gian hoặc tăng số lượng tham số [7]. Đối với

một tín hiệu đầu vào hai chiều x , đầu ra y tại vị trí $[i, j]$ được xác định bởi:

$$y[i, j] = \sum_{m=0}^{K-1} \sum_{n=0}^{K-1} x[i + r \cdot m, j + r \cdot n] \cdot w[m, n] \quad (1.19)$$

Trong đó r là hệ số giãn nở. Trường cảm nhận hiệu dụng k_e của một bộ lọc kích thước $k \times k$ được mở rộng theo công thức:

$$k_e = k + (k - 1)(r - 1) \quad (1.20)$$

Cơ chế này cực kỳ quan trọng đối với ảnh da liễu, nơi các vùng tổn thương có thể trải dài trên phạm vi lớn; việc sử dụng $r > 1$ giúp mô hình quan sát được ngữ cảnh rộng hơn mà vẫn giữ nguyên chi tiết tại từng pixel.


Module ASPP

Để giải quyết bài toán biến động đa thang đo (*multi-scale variability*) của các bệnh lý sắc tố, DeepLabV3+ sử dụng module ASPP[6]. Module này thực hiện các phép tích chập Atrous song song với các tốc độ giãn nở khác nhau, giúp mô hình "quan sát" vật thể ở nhiều tầm nhìn đồng thời:

$$\mathbf{Y} = \mathbf{W}_P \cdot \text{Concat} \left(\mathbf{W}_{1 \times 1} \mathbf{F}, \mathbf{W}_{3 \times 3, r=6} \mathbf{F}, \mathbf{W}_{3 \times 3, r=12} \mathbf{F}, \mathbf{W}_{3 \times 3, r=18} \mathbf{F}, \mathbf{W}_{\text{GAP}} \mathbf{f}_{\text{global}} \right) \quad (1.21)$$

Các thành phần bao gồm:

- Các nhánh tích chập Atrous 3×3 với $r \in \{6, 12, 18\}$ nhằm thu thập ngữ cảnh từ hẹp đến rộng.
- Nhánh Image Pooling: Thực hiện Global Average Pooling để nắm bắt đặc trưng toàn cục, sau đó nội suy song tuyến tính để đưa về kích thước ban đầu.
- Lớp chiếu $\mathbf{W}_P$: Sử dụng tích chập 1×1 để nén toàn bộ thông tin đã ghép nối về 256 kênh, tạo ra một biểu diễn nhúng giàu tính ngữ nghĩa cho bộ giải mã (*Decoder*).



Hình 1.4: Kiến trúc đa luồng của khối ASPP giúp khai thác ngữ cảnh đa thang đo trong phân đoạn ảnh.

1.5 Kiến trúc xử lý ngôn ngữ và trợ lý VQA

1.5.1 Cơ chế tự chú ý (Self-Attention) và kiến trúc Transformer

Để xử lý các mô tả bệnh lý dài và phức tạp trong mô-đun VQA, hệ thống ứng dụng kiến trúc Transformer dựa trên cơ chế tự chú ý (*Self-Attention*) [45]. Khác với CNN xử lý dữ liệu theo vùng cục bộ, Self-Attention cho phép mô hình tính toán sự phụ thuộc giữa tất cả các vị trí trong chuỗi đầu vào.

Cho một vector nhúng đầu vào $\mathbf{X}$, ta tính toán ba ma trận Query ($\mathbf{Q}$), Key ($\mathbf{K}$) và Value ($\mathbf{V}$) thông qua các phép chiếu tuyến tính: $\mathbf{Q} = \mathbf{XW}^Q$, $\mathbf{K} = \mathbf{XW}^K$, $\mathbf{V} = \mathbf{XW}^V$. Điểm số chú ý được xác định bằng tích vô hướng giữa Query và Key, sau đó chuẩn hóa bằng hàm Softmax:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{QK}^T}{\sqrt{d_k}} \right) \mathbf{V} \quad (1.22)$$

Trong đó $\sqrt{d_k}$ là hệ số tỷ lệ giúp ổn định đạo hàm. Trong mô hình DistilGPT-2 được triển khai, cơ chế này được thực thi theo dạng đa đầu (*Multi-head Attention*), cho phép mạng nơ-ron đồng thời tập trung vào các thông tin khác nhau trong câu hỏi lâm sàng tại nhiều không gian biểu diễn khác nhau.

1.5.2 Cơ sở toán học của kỹ thuật LoRA (Low-Rank Adaptation) trên mô hình ngôn ngữ

Để tinh chỉnh mô hình ngôn ngữ lớn (LLM) trong hệ thống VQA mà không cần cập nhật toàn bộ hàng tỷ tham số, đồ án áp dụng kỹ thuật LoRA (*Low-Rank Adaptation*) [19]. Phương pháp này dựa trên giả thuyết "Hạng bản chất thấp" (*Intrinsic Low-Rank*), cho rằng các ma trận cập nhật trọng số $\Delta \mathbf{W}$ trong quá trình thích nghi miền dữ liệu y tế có thể được biểu diễn hiệu quả qua phép phân rã thứ bậc thấp.

Xét một ma trận trọng số đóng băng $\mathbf{W}_0 \in \mathbb{R}^{d \times k}$ của lớp biến đổi tuyến tính trong DistilGPT-2, LoRA cấu trúc hóa ma trận cập nhật $\Delta \mathbf{W}$ dưới dạng tích của hai ma trận hạng thấp:

$$\Delta \mathbf{W} = \mathbf{B} \cdot \mathbf{A} \quad (1.23)$$

Trong đó $\mathbf{B} \in \mathbb{R}^{d \times r}$ và $\mathbf{A} \in \mathbb{R}^{r \times k}$, với hạng $r \ll \min(d, k)$. Trong triển khai thực tế của hệ thống, giá trị hạng được thiết lập $r = 8$. Phép toán truyền xuôi của lớp tuyến tính được điều chỉnh để tích hợp nhánh thích ứng song song:

$$\mathbf{h} = \mathbf{W}_0 \mathbf{x} + \Delta \mathbf{W} \mathbf{x} = \mathbf{W}_0 \mathbf{x} + \frac{\alpha}{r} (\mathbf{B} \mathbf{A} \mathbf{x}) \quad (1.24)$$

Trong đó $\alpha = 16$ là hằng số tỷ lệ (*scaling factor*) giúp ổn định hóa quá trình tối ưu hóa khi thay đổi giá trị r . Về mặt khởi tạo, ma trận $\mathbf{A}$ tuân theo phân phối Gauss $\mathcal{N}(0, \sigma^2)$ để phá vỡ tính đối xứng, trong khi ma trận $\mathbf{B}$ được khởi tạo bằng giá trị 0. Điều này đảm bảo tại thời điểm bắt đầu huấn luyện, nhánh LoRA không gây ra bất kỳ nhiễu nào lên đặc trưng gốc ($\Delta \mathbf{W} = \mathbf{0}$).

1.5.3 Tầng chiếu liên kết đa phương thức


Để căn chỉnh các đặc trưng thị giác từ EfficientNet-B1 vào không gian ngữ nghĩa của LLM, một tầng chiếu tuyến tính đa lớp (*Multilayer Projection*) được thiết lập. Tầng này đóng vai trò như một bộ thông dịch hình học, chuyển đổi vector đặc trưng ảnh $\mathbf{v} \in \mathbb{R}^{1280}$ sang vector nhúng ngôn ngữ $\mathbf{v}_{\text{proj}} \in \mathbb{R}^{768}$:

$$\mathbf{v}_{\text{proj}} = \mathbf{W}_{\text{proj2}} \cdot \text{GELU}(\mathbf{W}_{\text{proj1}} \cdot \mathbf{v} + \mathbf{b}_{\text{proj1}}) + \mathbf{b}_{\text{proj2}} \quad (1.25)$$

Tại đây, hàm kích hoạt GELU được sử dụng để duy trì tính phi tuyến và bảo toàn dòng chảy đạo hàm. Vector nhúng thị giác sau khi chiếu được coi như một "token hình ảnh" đặc biệt và được ghép nối vào đầu chuỗi nhúng văn bản:

$$\mathbf{H}_{\text{input}} = [\mathbf{v}_{\text{proj}}; \mathbf{t}_1; \mathbf{t}_2; \dots; \mathbf{t}_N] \in \mathbb{R}^{(1+N) \times 768} \quad (1.26)$$

Cấu trúc này cho phép cơ chế Attention của LLM tính toán sự tương quan trực tiếp giữa các vùng bệnh lý trong ảnh và các thuật ngữ lâm sàng trong câu hỏi.



Hình 1.5: Quy trình căn chỉnh không gian đặc trưng đa phương thức thông qua tầng chiếu MLP tuyến tính.

1.5.4 Cơ chế truy xuất RAG dựa trên độ tương đồng Cosine

Hệ thống RAG (*Retrieval-Augmented Generation*) được sử dụng để cung cấp tri thức y văn chính thống cho mô hình. Câu hỏi Q và các tài liệu tài liệu D_i trong cơ sở dữ liệu tri thức được mã hóa thành các vector nhúng dày đặc thông qua mô hình Sentence-Transformer ($d = 384$):

$$\mathbf{q} = E(Q), \quad \mathbf{d}_i = E(D_i) \quad (1.27)$$

Sự liên quan ngữ nghĩa được định lượng bằng độ tương đồng Cosine, một đại lượng đo lường góc giữa hai vector trong không gian Euclid cao chiều:

$$\text{Sim}(Q, D_i) = \frac{\mathbf{q} \cdot \mathbf{d}_i}{\|\mathbf{q}\| \|\mathbf{d}_i\|} = \frac{\sum_{k=1}^d q_k d_{i,k}}{\sqrt{\sum_{k=1}^d q_k^2} \sqrt{\sum_{k=1}^d d_{i,k}^2}} \quad (1.28)$$

Các đoạn văn bản có Sim cao nhất sẽ được trích xuất làm ngữ cảnh (*Context*) đính kèm vào Prompt đầu vào, giúp LLM thực hiện suy luận dựa trên bằng chứng y văn thay vì tự sinh văn bản ngẫu nhiên.

1.6 Các giải thuật hỗ trợ và chuẩn hóa y tế

1.6.1 Giải thích mô hình bằng thuật toán Grad-CAM

Để minh bạch hóa quá trình chẩn đoán, Grad-CAM (*Gradient-weighted Class Activation Mapping*) được sử dụng để tạo ra bản đồ nhiệt vùng tổn thương[37]. Trọng số đóng góp α_k^c của mỗi bản đồ đặc trưng thứ k đối với lớp bệnh lý c được tính toán bằng cách lấy trung bình toàn cục đạo hàm của điểm số dự đoán y^c :

$$\alpha_k^c = \frac{1}{U \cdot V} \sum_{i=1}^U \sum_{j=1}^V \frac{\partial y^c}{\partial A_{i,j}^k} \quad (1.29)$$

Bản đồ nhiệt cuối cùng là tổ hợp tuyến tính của các bản đồ đặc trưng, được lọc qua hàm ReLU để chỉ giữ lại các đặc trưng có tác động tích cực đến việc dự báo bệnh lý:

$$L_{\text{Grad-CAM}}^c = \text{ReLU} \left(\sum_k \alpha_k^c \mathbf{A}^k \right) \quad (1.30)$$

1.6.2 Phân tích độ sắc nét qua toán tử Laplacian và Hessian

Hệ thống kiểm soát chất lượng ảnh đầu vào sử dụng toán tử Laplacian để đo lường hàm lượng tần số cao (các cạnh sắc nét). Toán tử Laplacian ΔI của hàm cường độ ảnh $I(x, y)$ là vết của ma trận Hessian:

$$\Delta I = \text{Tr}(\mathbf{H}(I)) = \frac{\partial^2 I}{\partial x^2} + \frac{\partial^2 I}{\partial y^2} \quad (1.31)$$

Trong xử lý ảnh số, toán tử này được thực thi qua tích chập với kernel rời rạc $\mathbf{K}_L$. Độ sắc nét (*blur_score*) được định nghĩa là phương sai của bản đồ Laplacian, đặc trưng cho mức độ biến thiên cường độ tại các ranh giới vật thể:

$$\text{blur_score} = \text{Var}(\mathbf{K}_L * I_{\text{gray}}) \quad (1.32)$$

1.6.3 Kiểm soát phơi sáng thích ứng và công bằng thuật toán

Để đảm bảo tính công bằng (*Fairness*) theo thang đo Fitzpatrick (Type I-VI)[13], hệ thống áp dụng cơ chế ngưỡng phơi sáng động. Độ sáng trung bình μ_I được xác định qua kỳ vọng thống kê của cường độ xám:

$$\mu_I = \frac{1}{H \cdot W} \sum_{x=1}^W \sum_{y=1}^H I_{\text{gray}}(x, y) \quad (1.33)$$

Thay vì sử dụng một ngưỡng cố định dễ gây thiên kiến với người da tối, hệ thống điều chỉnh ngưỡng dựa trên độ sắc nét:

$$\text{Threshold}_{\min} = \begin{cases} 30.0 & \text{nếu } \text{blur_score} \geq 100.0 \text{ (Ảnh đủ nét)} \\ 50.0 & \text{trường hợp khác} \end{cases} \quad (1.34)$$

Nếu $\mu_I \notin [\text{Threshold}_{\min}, 210.0]$, hệ thống sẽ kích hoạt rào chắn an toàn (*Safety Gate*) để từ chối xử lý, tránh đưa ra các dự đoán sai lệch do lỗi thu nhận ảnh.

1.6.4 Mô hình hợp nhất đa phương thức Bayes

Nhằm khai thác tối đa mối tương quan giữa đặc trưng thị giác và các yếu tố dịch tễ học, hệ thống triển khai cơ chế hợp nhất muộn (*Late Fusion*) dựa trên khung lý thuyết xác suất Bayes. Phương pháp này cho phép hiệu chỉnh kết quả chẩn đoán dựa trên dữ liệu lâm sàng của bệnh nhân (Tuổi, Giới tính, Vị trí tổn thương).

Giả sử không gian nhãn gồm $N = 7$ lớp bệnh lý $C_i \in \{C_1, \dots, C_7\}$. Gọi $\mathbf{V}$ là tensor đặc trưng thị giác và $\mathbf{D} = \{d_{\text{age}}, d_{\text{gender}}, d_{\text{loc}}\}$ là tập hợp các biến dịch tễ. Xác suất hậu nghiệm hợp nhất $P(C_i|\mathbf{V}, \mathbf{D})$ được xác định thông qua tổ hợp trọng số trong không gian xác suất:

$$P(C_i|\mathbf{V}, \mathbf{D}) = \frac{[P(C_i|\mathbf{V})]^\lambda \cdot [P(C_i|\mathbf{D})]^{1-\lambda}}{\sum_{j=1}^7 [P(C_j|\mathbf{V})]^\lambda \cdot [P(C_j|\mathbf{D})]^{1-\lambda}} \quad (1.35)$$

Trong đó:

- $P(C_i|\mathbf{V})$ là phân phối xác suất đầu ra từ nhánh Computer Vision (EfficientNet-B1 + CBAM) sau hàm Softmax.
- $\lambda \in [0.5, 1.0]$ là hệ số tin cậy (*confidence weight*) điều tiết mức độ ảnh hưởng của hình ảnh so với bệnh sử.
- $P(C_i|\mathbf{D})$ là phân phối xác suất tiên nghiệm dựa trên dịch tễ học, được tính toán theo mô hình Naive Bayes dưới giả định các yếu tố bệnh nhân độc lập có điều kiện:

$$P(C_i|\mathbf{D}) = \frac{P(C_i) \cdot P(d_{\text{age}}|C_i) \cdot P(d_{\text{gender}}|C_i) \cdot P(d_{\text{loc}}|C_i)}{P(\mathbf{D})} \quad (1.36)$$

Các phân phối xác suất thành phần được ước lượng bằng phương pháp hợp lý cực đại (*Maximum Likelihood Estimation*) dựa trên thống kê tần suất từ 10.015 mẫu thuộc tập dữ liệu HAM10000[44]. Giúp mô hình nắm bắt được các đặc thù phân bố bệnh lý theo nhóm đối tượng và vị trí cơ thể.

1.6.5 Giải thuật phân đoạn tương tác và cơ chế dự phòng an toàn

Bên cạnh cơ chế phân đoạn tự động (*Automatic Segmentation*) bằng DeepLabV3+, hệ thống cung cấp khả năng can thiệp của chuyên gia thông qua tương tác điểm mồi (*Prompt-based Interaction*) để khoanh vùng các tổn thương phức tạp.

Toán tử tương tác điểm môi và thuật toán GrabCut Fallback

Tại chế độ tương tác, khi bác sĩ cung cấp một tọa độ chỉ định (x_c, y_c) , hệ thống ưu tiên sử dụng kiến trúc MobileSAM để phân tách mặt nạ[47]. Nhằm đảm bảo tính sẵn sàng trên các thiết bị cấu hình thấp hoặc khi thiếu tài nguyên GPU, hệ thuật toán tự động chuyển đổi sang cơ chế GrabCut dựa trên tối ưu hóa năng lượng đồ thị[35]. Một vùng bao mục tiêu R_F được xác lập tự động:

$$R_F = \left[x_c - \frac{0.35W}{2}, x_c + \frac{0.35W}{2} \right] \times \left[y_c - \frac{0.35H}{2}, y_c + \frac{0.35H}{2} \right] \quad (1.37)$$

GrabCut thực hiện cực tiểu hóa hàm năng lượng Gibbs E để tách biệt vùng tiền cảnh (tổn thương) và hậu cảnh (da lành):

$$E(\alpha, \mathbf{k}, \mathbf{w}, \mathbf{z}) = U(\alpha, \mathbf{k}, \mathbf{w}, \mathbf{z}) + V(\alpha, \mathbf{z}) \quad (1.38)$$

Trong đó U biểu diễn độ phù hợp của dữ liệu pixel với mô hình GMM (*Gaussian Mixture Model*) và V biểu diễn tính liên tục về mặt không gian của mặt nạ phân đoạn.

Cơ chế dự phòng an toàn

Để ngăn chặn sai số do tương tác người dùng không chính xác (ví dụ: click vào vùng da lành), hệ thống tích hợp bộ lọc diện tích mặt nạ. Nếu diện tích vùng phân đoạn tương tác M_{inter} không đạt ngưỡng tối thiểu để thực hiện phép đo ABCD, thuật toán sẽ tự động khôi phục kết quả từ mô hình DeepLabV3+:

$$M_{\text{final}} = \begin{cases} M_{\text{inter}} & \text{nếu } \text{Area}(M_{\text{inter}}) \geq 100 \text{ px} \\ M_{\text{auto}} & \text{nếu } \text{Area}(M_{\text{inter}}) < 100 \text{ px} \end{cases} \quad (1.39)$$

Quy trình này đảm bảo luồng phân tích tính toán đặc trưng hình học (ABCD features) luôn được cung cấp dữ liệu hợp lệ, duy trì tính ổn định của hệ thống chẩn đoán.

1.6.6 Xử lý tương thích định dạng dữ liệu y khoa DICOM

Để đảm bảo tính liên thông trong môi trường bệnh viện, hệ thống hỗ trợ chuẩn DICOM (*Digital Imaging and Communications in Medicine*)[1]. Quy trình xử lý tệp tin .dcm được thực thi qua hai nhánh xử lý song song:

1. **Chuẩn hóa cường độ Pixel (Intensity Rescaling):** Dữ liệu thô từ thẻ `PixelData` (07FE, 0010) thường có dải động lớn hơn 8-bit. Hệ thống thực hiện ánh xạ tuyến tính dựa trên các giá trị cửa sổ quan sát (*Windowing*) để đưa về không gian RGB 24-bit phục vụ các mô hình AI:

$$I_{\text{out}} = \text{clamp} \left(\frac{I_{\text{in}} - (\text{WC} - 0.5)}{\text{WW} - 1} \times 255, 0, 255 \right) \quad (1.40)$$

Trong đó WC là Window Center (0028, 1050) và WW là Window Width (0028, 1051).

2. **Ánh xạ thực thể siêu dữ liệu (Metadata Mapping):** Các thông tin định danh và lâm sàng được trích xuất tự động để làm giàu dữ liệu cho mô hình Bayes:

- **Danh tính:** Trích xuất từ thẻ *Patient's Name* (0010, 0010).
- **Dịch tễ học:** Thẻ *Patient's Sex* (0010, 0040) cung cấp giới tính. Tuổi bệnh nhân A được tính toán động từ thẻ *Patient's Birth Date* (0010, 0030) và ngày thực hiện xét nghiệm: $A = \text{Year}(\text{StudyDate}) - \text{Year}(\text{BirthDate})$.

Việc xử lý trực tiếp DICOM giúp giảm thiểu sai số do nén ảnh và mất mát dữ liệu meta, đồng thời tuân thủ các quy chuẩn về lưu trữ thông tin lâm sàng hiện nay.

1.7 Hàm mất mát và các tiêu chí đánh giá hệ thống

1.7.1 Các hàm mất mát (Dice, BCE, Combined Loss)

Dice Loss

a) Định nghĩa và Cơ sở toán học

Định nghĩa 1.6 Dice Loss là hàm mất mát được xây dựng dựa trên chỉ số Dice Coefficient (hay F1-score trong phân đoạn), dùng để đo lường độ tương đồng giữa hai tập hợp dữ liệu [Dice1945].

Chỉ số Dice (Dice Coefficient): Xét hai tập hợp A và B (tương ứng với mặt nạ dự đoán và mặt nạ thực tế), chỉ số Dice được xác định bởi:

$$\text{Dice}(A, B) = \frac{2|A \cap B|}{|A| + |B|}$$

Trong đó:

- $|A \cap B|$ đại diện cho diện tích vùng chồng lấp (intersection) giữa dự đoán và thực tế.
- $|A|$ và $|B|$ là tổng số phần tử của từng tập hợp.
- Hệ số 2 nhằm chuẩn hóa kết quả về khoảng $[0, 1]$.

Dice Loss: Để tối ưu hóa mạng nơ-ron theo hướng cực tiểu hóa sai số, Dice Loss được định nghĩa là phần bù của chỉ số Dice:

$$\mathcal{L}_{\text{Dice}} = 1 - \text{Dice}(A, B)$$

b) Công thức trong phân đoạn ảnh

Với bản đồ xác suất dự đoán $\mathbf{P} \in [0, 1]^{H \times W}$ và mặt nạ thực tế $\mathbf{G} \in \{0, 1\}^{H \times W}$:

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_{i,j} P_{ij} G_{ij} + \epsilon}{\sum_{i,j} P_{ij} + \sum_{i,j} G_{ij} + \epsilon}$$

Trong đó ϵ (thường bằng 1) là hằng số làm mịn (*smoothing constant*) nhằm tránh lỗi chia cho 0 và ổn định quá trình hội tụ.

c) Ưu điểm trong phân đoạn tổn thương da

Dice Loss đặc biệt hiệu quả trong các dự án chẩn đoán hình ảnh y tế sử dụng mô hình U-Net nhờ các đặc tính:

- **Tối ưu hóa trực tiếp metric:** Hàm mất mát này trực tiếp cải thiện chỉ số Dice - thước đo quan trọng nhất trong phân đoạn ảnh.
- **Khả năng chống mất cân bằng lớp (Robustness):** Trong ảnh soi da, vùng tổn thương thường chỉ chiếm tỷ lệ rất nhỏ (ví dụ: 1.2%) so với vùng da lành (98.8%). Dice Loss tập trung vào vùng chồng lấp thay vì bị chi phối bởi số lượng lớn các pixel nền (background) [Sudre2017].

Binary Cross-Entropy (BCE)

Định nghĩa 1.7 Binary Cross-Entropy là hàm mất mát tiêu chuẩn cho các bài toán phân loại nhị phân [14]. Trong bài toán phân đoạn ảnh, mỗi pixel được coi là một nhiệm vụ phân loại độc lập:

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{HW} \sum_{i,j} [G_{ij} \log(P_{ij}) + (1 - G_{ij}) \log(1 - P_{ij})]$$

Ưu điểm: BCE đánh giá sai số tại từng pixel riêng lẻ, giúp mô hình học tốt các chi tiết tại đường biên của nốt ruồi hoặc tổn thương, đồng thời cung cấp gradient ổn định cho quá trình lan truyền ngược.

Hàm mất mát kết hợp (Combined Loss) cho phân đoạn

Trong bài toán phân đoạn vùng tổn thương da, do diện tích vùng bệnh lý thường chiếm tỷ trọng rất nhỏ so với vùng da lành (mất cân bằng lớp giữa tiền cảnh và hậu cảnh), hệ thống sử dụng hàm mất mát kết hợp giữa *Binary Cross-Entropy* (BCE) và *Dice Loss*[24]:

$$\mathcal{L}_{\text{total}} = \lambda \cdot \mathcal{L}_{\text{Dice}} + (1 - \lambda) \cdot \mathcal{L}_{\text{BCE}} \quad (1.41)$$

Trong đó, trọng số $\lambda = 0.6$ được thiết lập để ưu tiên tối ưu hóa độ trùng khớp vùng khối.

- **Dice Loss:** Trực tiếp tối ưu hóa hệ số Dice, giúp mô hình tập trung vào việc tạo ra sự giao thoa tối đa giữa mặt nạ dự đoán (P) và mặt nạ chuẩn (G):

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2|P \cap G| + \epsilon}{|P| + |G| + \epsilon} \quad (1.42)$$

- **BCE Loss:** Giúp ổn định quá trình huấn luyện bằng cách tính toán sai số entropy tại từng vị trí pixel:

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N [g_i \log(p_i) + (1 - g_i) \log(1 - p_i)] \quad (1.43)$$

1.7.2 Các thước đo định lượng

Để đánh giá toàn diện hiệu năng của hệ thống đa nhiệm, đề án sử dụng tập hợp các thước đo chuẩn mực trong y văn:

Thước đo cho bài toán phân đoạn (Segmentation)

- **Mean Intersection over Union (mIoU):** Đo lường tỷ lệ giữa diện tích phần giao và phần hợp của vùng dự đoán so với vùng thực tế. Đây là chỉ số quan trọng nhất để đánh giá độ chính xác của ranh giới tổn thương:

$$\text{IoU} = \frac{|P \cap G|}{|P \cup G|} = \frac{TP}{TP + FP + FN} \quad (1.44)$$

- **Dice Coefficient (F1-Pixel):** Tương đương với F1-score ở cấp độ điểm ảnh, đo lường sự hài hòa giữa độ nhạy và độ đặc hiệu của mặt nạ phân đoạn.

Thước đo cho bài toán phân loại (Classification)

Đối với chẩn đoán 7 lớp bệnh lý trên bộ dữ liệu mất cân bằng 10000, hệ thống sử dụng các chỉ số dựa trên ma trận nhầm lẫn (*Confusion Matrix*):

- **Accuracy (Độ chính xác tổng thể):** Tỷ lệ dự đoán đúng trên tổng số mẫu.
- **Precision (Độ chính xác dự báo):** Khả năng mô hình không gán nhầm sai cho một người lành.
- **Recall/Sensitivity (Độ nhạy):** Khả năng quan trọng nhất trong y tế, đo lường tỷ lệ bỏ sót bệnh nhân trong các ca bệnh thực tế:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (1.45)$$

- **Macro-average F1-Score:** Trung bình cộng F1-score của từng lớp. Chỉ số này phản ánh khách quan năng lực của mô hình trên các lớp dữ liệu hiếm (như Melanoma) mà không bị che lấp bởi các lớp chiếm đa số.

Chương 2

Thiết kế hệ thống và xây dựng phương pháp

2.1 Khảo sát các phương pháp chẩn đoán bệnh da liễu hiện có

2.1.1 Phương pháp truyền thống và các giới hạn vật lý

Quan sát lâm sàng bằng mắt thường

Quan sát lâm sàng là phương pháp tiếp cận sơ cấp, dựa trên tri thức kinh nghiệm để đánh giá hình thái tổn thương. Quy tắc ABCD [41] được chuẩn hóa để định lượng hóa các dấu hiệu:

- **A (Asymmetry):** Tính bất đối xứng của tổn thương qua hai trục vuông góc.
- **B (Border):** Sự không đều hoặc mờ nhòe của đường biên.
- **C (Color):** Sự hiện diện của nhiều tông màu (đen, nâu, đỏ, trắng, xanh).
- **D (Diameter):** Đường kính lớn hơn 6mm.

Tuy nhiên, năng lực phân giải của mắt người bị giới hạn ở dải ánh sáng khả kiến và không thể nhận diện các biến đổi ở mức độ tế bào. Độ chính xác của phương pháp này chỉ đạt khoảng 60% – 80%, dẫn đến tỷ lệ âm tính giả cao trong chẩn đoán ung thư hắc tố giai đoạn đầu [21].

Dermatoscopy thủ công qua lăng kính quang học

Soi da kỹ thuật số là sự kết hợp giữa kỹ thuật soi da truyền thống và công nghệ xử lý ảnh số, cho phép thu nhận, lưu trữ và phân tích dữ liệu trên các hệ thống máy tính chuyên dụng.

Chức năng cốt lõi:

- **Quản lý dữ liệu tập trung:** Hình ảnh được lưu trữ dưới định dạng số hóa, giúp việc quản lý hồ sơ bệnh án trở nên khoa học và lâu dài.
- **Theo dõi theo trình tự (Sequential dermoscopy):** So sánh ảnh của cùng một tổn thương tại các thời điểm khác nhau để phát hiện sớm các dấu hiệu tiến triển ác tính.
- **Hỗ trợ chẩn đoán bằng AI:** Tích hợp các thuật toán học máy để phân tích đặc trưng hình ảnh, cung cấp điểm số nguy cơ (risk score) hỗ trợ bác sĩ.
- **Y tế từ xa (Telemedicine):** Dữ liệu hình ảnh được truyền tải qua mạng lưới kỹ thuật số để nhận tư vấn từ các chuyên gia đầu ngành ở xa.
- **Đào tạo chuyên môn:** Kho dữ liệu hình ảnh phong phú phục vụ mục đích giảng dạy và huấn luyện các mô hình AI.

Các hệ thống thương mại tiêu biểu:

- **FotoFinder (Đức):** Tích hợp bản đồ hóa toàn thân (total body mapping) và trí tuệ nhân tạo để tầm soát sớm ung thư da.
- **Canfield Veos DS3 (Mỹ):** Thiết bị soi da kỹ thuật số độ phân giải cao (20MP).
- **MoleMax (Áo):** Cung cấp các công cụ phân tích tự động và đánh giá rủi ro.
- **DermEngine:** Nền tảng dựa trên điện toán đám mây cho phép kết nối và tư vấn từ xa chuyên nghiệp.

Dermatoscopy sử dụng hệ thống thấu kính kết hợp ánh sáng phân cực để loại bỏ phản xạ bề mặt của lớp sừng (*stratum corneum*), cho phép quan sát cấu trúc dưới bề mặt da. Kỹ thuật này giúp bác sĩ nhận diện các đặc trưng

vi mô như mạng lưới hắc tố (*pigment network*) hay các điểm cục (*dots and globules*). Mặc dù nâng độ chính xác lên 80% – 95%, nhưng nó vẫn mang tính chủ quan và đòi hỏi thời gian đào tạo chuyên sâu.

Sinh thiết mô bệnh học (Biopsy) - Tiêu chuẩn vàng lâm sàng

Sinh thiết là quy trình cắt bỏ mẫu mô bệnh lý để quan sát dưới kính hiển vi sau khi nhuộm H&E. Kết quả sinh thiết được coi là tập nhãn chuẩn (Ground Truth) $\mathcal{Y}^*$. Ta có thể biểu diễn xác suất chẩn đoán đúng của sinh thiết là:

$$P(\hat{y} = y^* | \mathcal{D}_{\text{biopsy}}) \approx 1.0 \quad (2.1)$$

Tuy nhiên, đây là phương pháp xâm lấn, tốn chi phí và thời gian (3-7 ngày), không phù hợp cho sàng lọc quy mô lớn.

2.1.2 Sự phát triển của công nghệ chẩn đoán dựa trên hình ảnh số hóa

Kính hiển vi laser tiêu điểm (Confocal Laser Scanning Microscopy - RCM)

RCM sử dụng tia laser bước sóng 830nm để quét lớp biểu bì theo mặt ngang. Nhờ lỗ kim quang học (*pinhole*), hệ thống loại bỏ các photon tán xạ ngoài tiêu điểm, cho phép thu nhận hình ảnh có độ phân giải tương đương mô bệnh học mà không cần xâm lấn [32]. Kính hiển vi laser tiêu điểm là một bước tiến đột phá, cho phép bác sĩ quan sát chi tiết cấu trúc tế bào da tại các độ sâu khác nhau ở mức độ vi thể mà không cần can thiệp sinh thiết xâm lấn.

Ứng dụng lâm sàng:

- **Phân biệt bệnh lý:** Hỗ trợ phân biệt giữa u hắc tố ác tính (melanoma) và các nốt ruồi lành tính dựa trên cấu trúc tế bào.
- **Xác định biên tổn thương:** Hỗ trợ lập kế hoạch phẫu thuật bằng cách xác định chính xác ranh giới của vùng bệnh lý.
- **Theo dõi điều trị:** Đánh giá đáp ứng của bệnh nhân đối với các phác đồ điều trị nội khoa hoặc xạ trị thông qua việc quan sát sự thay đổi cấu trúc tế bào theo thời gian.

- **Nghiên cứu khoa học:** Công cụ đắc lực trong việc tìm hiểu cơ chế bệnh sinh và thử nghiệm các loại dược phẩm mới.

Siêu âm da tần số cao (High-Frequency Ultrasound)

Siêu âm sử dụng sóng âm 20 – 100 MHz để đo độ dày Breslow (T_B) - chỉ số quan trọng nhất trong tiên lượng Melanoma [3]. Độ sâu xâm lấn được tính dựa trên thời gian phản hồi của xung âm giữa ranh giới các lớp mô có trở kháng âm khác nhau. **Ứng dụng tiêu biểu:**

- **Đo độ dày tổn thương:** Đặc biệt quan trọng trong chẩn đoán melanoma để đo độ dày Breslow (Breslow thickness) một cách không xâm lấn – đây là yếu tố tiên lượng quan trọng nhất trong ung thư da.
- **Đánh giá hạch bạch huyết:** Phát hiện sự xâm lấn và thay đổi hình thái của hạch lympho, hỗ trợ phân giai đoạn (staging) ung thư da.
- **Giám sát điều trị:** Theo dõi sự thu hẹp kích thước tổn thương sau các liệu pháp điều trị.
- **Hướng dẫn can thiệp:** Xác định vị trí tối ưu để thực hiện sinh thiết, nhất là đối với các khối u nằm sâu dưới lớp hạ bì.

Soi da kỹ thuật số và FotoFinder

Hệ thống FotoFinder tích hợp cảm biến CMOS và công nghệ SDDI (*Sequential Digital Dermoscopy Imaging*), cho phép thực hiện phép hiệu ảnh giữa các mốc thời gian t_i và t_j để phát hiện sự thay đổi cấu trúc nhỏ nhất: $\Delta I = |I_{t_j} - I_{t_i}|$.

Chức năng cốt lõi:

- **Quản lý dữ liệu tập trung:** Hình ảnh được lưu trữ dưới định dạng số hóa, giúp việc quản lý hồ sơ bệnh án trở nên khoa học và lâu dài.
- **Theo dõi theo trình tự (Sequential dermoscopy):** So sánh ảnh của cùng một tổn thương tại các thời điểm khác nhau để phát hiện sớm các dấu hiệu tiến triển ác tính.
- **Hỗ trợ chẩn đoán bằng AI:** Tích hợp các thuật toán học máy để phân tích đặc trưng hình ảnh, cung cấp điểm số nguy cơ (risk score) hỗ trợ bác sĩ.

- **Y tế từ xa (Telemedicine):** Dữ liệu hình ảnh được truyền tải qua mạng lưới kỹ thuật số để nhận tư vấn từ các chuyên gia đầu ngành ở xa.
- **Đào tạo chuyên môn:** Kho dữ liệu hình ảnh phong phú phục vụ mục đích giảng dạy và huấn luyện các mô hình AI.

Các hệ thống thương mại tiêu biểu:

- **FotoFinder (Đức):** Tích hợp bản đồ hóa toàn thân (total body mapping) và trí tuệ nhân tạo để tầm soát sớm ung thư da.
- **Canfield Veos DS3 (Mỹ):** Thiết bị soi da kỹ thuật số độ phân giải cao (20MP).
- **MoleMax (Áo):** Cung cấp các công cụ phân tích tự động và đánh giá rủi ro.
- **DermEngine:** Nền tảng dựa trên điện toán đám mây cho phép kết nối và tư vấn từ xa chuyên nghiệp.

2.1.3 Kỹ nguyên học máy truyền thống và kỹ nghệ đặc trưng

Trước học sâu, quy trình dựa trên việc trích xuất thủ công các đặc trưng hình thái (*hand-crafted features*).

Thuật toán 1: Quy trình Học máy truyền thống phân loại ảnh da liễu

Input: Ảnh thô $I \in \mathbb{R}^{H \times W \times 3}$

Output: Nhận dự đoán $\hat{c}$

- 1 $I_{\text{clean}} \leftarrow \text{DullRazor}(I)$; // Sử dụng phép đóng hình thái học để khử lông [23]
 - 2 $M \leftarrow \text{Otsu}(I_{\text{clean}})$; // Cực đại hóa phương sai giữa các lớp
 - 3 $\mathbf{f}_{\text{texture}} \leftarrow \text{GLCM}(I_{\text{clean}}, M)$; // Trích xuất ma trận đồng xuất hiện xám [15]
 - 4 $\mathbf{f}_{\text{color}} \leftarrow [\mu, \sigma, \gamma, \kappa]$; // Mô-men màu sắc bậc 1-4
 - 5 $\hat{c} \leftarrow \text{Classifier}(\text{PCA}(\mathbf{f}_{\text{all}}))$; // Phân loại bằng SVM hoặc Random Forest
 - 6 return $\hat{c}$
-

Trích xuất đặc trưng kết cấu qua ma trận GLCM

Để mô tả độ mịn, nhám của vùng tổn thương, hệ thống tính toán ma trận đồng xuất hiện mức xám (*Gray-Level Co-occurrence Matrix* - GLCM) [15]. Một phần tử $P(i, j|d, \theta)$ biểu thị xác suất hai điểm ảnh có mức xám i và j xuất hiện cách nhau một khoảng d theo hướng θ . Từ đó tính toán các chỉ số toán học bậc cao:

$$\text{Energy} = \sum_{i,j} P_{i,j}^2, \quad \text{Contrast} = \sum_{i,j} |i-j|^2 P_{i,j}, \quad \text{Entropy} = - \sum_{i,j} P_{i,j} \log P_{i,j} \quad (2.2)$$

Mô hình Máy vectơ hỗ trợ (SVM) và Bài toán đối ngẫu

SVM tìm siêu phẳng phân cách có lề lớn nhất trong không gian đặc trưng. Bằng cách sử dụng hàm nhân RBF $K(\mathbf{x}_i, \mathbf{x}_j)$, ta giải bài toán tối ưu đối ngẫu Lagrange [10]:

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j) - \sum_{i=1}^N \alpha_i \quad (2.3)$$

Ràng buộc: $\sum_{i=1}^N \alpha_i y_i = 0$ và $0 \leq \alpha_i \leq C$. Hàm quyết định cuối cùng có dạng:

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i \in SV} \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + b \right) \quad (2.4)$$

Mô hình Rừng ngẫu nhiên và Chỉ số Gini

Random Forest xây dựng B cây quyết định dựa trên lấy mẫu *Bootstrap*. Tại mỗi nút, tiêu chí phân tách dựa trên việc giảm độ tạp chất Gini [2]:

$$\Delta G = G_{\text{parent}} - \frac{N_{\text{left}}}{N} G_{\text{left}} - \frac{N_{\text{right}}}{N} G_{\text{right}} \quad (2.5)$$

Trong đó $G = 1 - \sum_{k=1}^K p_k^2$ là chỉ số Gini của nút.

2.1.4 Kỹ nguyên Học sâu trong Phân tích ảnh Đa liễu

Học sâu thay thế việc thiết kế đặc trưng thủ công bằng quá trình học tự động các bộ lọc không gian.

Phân đoạn ngữ nghĩa tổn thương da

Hệ thống sử dụng U-Net [34] và DeepLabV3+ [6]. Trong mã nguồn v7.2, DeepLabV3+ được ưu tiên để trích xuất ngữ cảnh đa thang đo qua khối ASPP, đảm bảo ranh giới tổn thương chính xác cho các phép đo ABCD sau này.

Phân loại đa lớp bệnh lý

Backbone EfficientNet-B1 [43] thực hiện trích xuất đặc trưng với 1280 chiều. Việc sử dụng cơ chế *Residual Learning* [17] giúp mạng học được các ánh xạ đồng nhất $H(\mathbf{x}) = \mathcal{F}(\mathbf{x}) + \mathbf{x}$, triệt tiêu hiện tượng tiêu biến đạo hàm trong các tầng sâu của mô hình.

2.2 Kết luận lựa chọn kiến trúc mô hình

Dựa trên các phân tích thực nghiệm và ràng buộc về tài nguyên CPU, hệ thống được chuẩn hóa dựa trên hai trụ cột kiến trúc tối ưu:

2.2.1 Hệ thống Phân đoạn: Mạng DeepLabV3+ kết hợp Multi-Scale TTA

Nhằm xử lý sự biến động về tiêu cự và khoảng cách chụp trong ảnh lâm sàng không chuẩn hóa, đề án lựa chọn kiến trúc DeepLabV3+ với xương sống ResNet50 [6]. Để tăng cường độ chính xác tại thời điểm suy luận (*inference time*), hệ thống tích hợp kỹ thuật Tăng cường đa tỷ lệ (Multi-Scale Test-Time Augmentation - TTA) [26].

Quá trình hợp nhất thông tin không gian đa tỷ lệ được thực hiện như sau:

1. **Phân rã Scale-Space:** Tạo các biến thể của ảnh đầu vào thông qua toán tử cắt trung tâm (*center crop*) với các tỷ lệ tỷ lệ không gian $s \in \mathcal{S} = \{1.0, 0.75, 0.5\}$.
2. **Suy luận song song:** Đưa tập hợp ảnh qua mô hình DeepLabV3+ để thu được các bản đồ xác suất đơn lẻ $P_s(x, y) = f_{\text{Seg}}(\mathbf{X}_s)$.
3. **Hợp nhất xác suất (Ensemble):** Thực hiện nội suy song tuyến tính (*Bilinear Interpolation*) đưa các bản đồ xác suất về không gian tọa độ

gốc $\mathbf{X}$ và tính trung bình cộng phân phối:

$$P_{\text{TTA}}(x, y) = \frac{1}{|\mathcal{S}(x, y)|} \sum_{s \in \mathcal{S}(x, y)} P_s(x, y) \quad (2.6)$$

Trong đó $\mathcal{S}(x, y)$ là tập hợp các thang đo bao phủ tọa độ (x, y) .

4. **Lượng hóa mặt nạ:** Áp dụng ngưỡng cắt $\tau = 0.3$ để sinh mặt nạ nhị phân cuối cùng, đảm bảo tính bao phủ ranh giới tổn thương:

$$\hat{M}(x, y) = \begin{cases} 1 & \text{nếu } P_{\text{TTA}}(x, y) \geq 0.3 \\ 0 & \text{ngược lại} \end{cases} \quad (2.7)$$

2.2.2 Hệ thống Phân loại: EfficientNet-B1 tích hợp Lớp chú ý CBAM

Với mục tiêu triển khai thực tế trên các thiết bị đầu cuối không có GPU mạnh, đề án sử dụng EfficientNet-B1 [43] làm nhân trích xuất đặc trưng. Ảnh vùng quan tâm (ROI) được chuẩn hóa về kích thước 224×224 pixels. Hệ thống tích hợp module chú ý kép CBAM [46] ngay sau khối MBConv cuối cùng để tinh chỉnh dòng chảy đặc trưng:

- **Tối ưu hóa tài nguyên:** Với cơ chế *Compound Scaling*, mô hình đạt tốc độ suy luận $\approx 60\text{ms}/\text{ảnh}$ trên CPU, đáp ứng yêu cầu phản hồi tức thời.
- **Hiệu chuẩn đặc trưng (Feature Calibration):** CBAM thực hiện tái định lượng các kênh đặc trưng dựa trên trọng số chú ý, giúp mô hình tập trung vào các biến đổi sắc tố vi mô (như dấu hiệu *Blue-white veil* trong Melanoma) thay vì các vùng da lành bao quanh.

2.3 Kiến trúc tổng quan hệ thống và Luồng xử lý

Hệ thống được thiết kế theo kiến trúc hướng mô-đun hóa (*Modular Pipeline*), đảm bảo tính độc lập và khả năng mở rộng của từng giai đoạn xử lý.

2.3.1 Sơ đồ quy trình luồng xử lý dữ liệu tổng thể (Pipeline)



Hình 2.1: Sơ đồ luồng xử lý dữ liệu tuần tự và kiến trúc phân lớp của hệ thống.

2.3.2 Vai trò toán học và chức năng chuyên biệt của các mô-đun

- Mô-đun Safety Gate QA:** Sử dụng toán tử vi phân Laplacian $\nabla^2 I$ để xác định phương sai cường độ. Nếu $\sigma^2(\nabla^2 I) < \tau_{\text{blur}}$, ảnh bị từ chối do thiếu độ nét vật lý. Cơ chế phơi sáng thích ứng đảm bảo tính công bằng thuật toán (*Algorithmic Fairness*) cho mọi tông màu da.
- Mô-đun Phân đoạn đa chế độ:** Tạo mặt nạ $\hat{M} \in \{0, 1\}^{H \times W}$. Áp dụng thuật toán dự phòng an toàn để bảo vệ tính sẵn sàng:

$$\hat{M}_{\text{final}} = \begin{cases} \hat{M}_{\text{inter}} & \text{nếu } \text{Area}(\hat{M}_{\text{inter}}) \geq 100 \text{ px} \\ \hat{M}_{\text{auto}} & \text{trường hợp khác} \end{cases} \quad (2.8)$$

- **Mô-đun Trích xuất ROI và ABCD Metrics:** Xác định vùng bao cực trị $(x_{\min}, y_{\min}, x_{\max}, y_{\max})$ từ $\hat{M}$. Một vùng đệm $\delta = 10$ px được thêm vào để bảo toàn ngữ cảnh biên. Ảnh ROI được *resize* về 224×224 pixels phục vụ phân loại. Đồng thời, tính toán các chỉ số ABCD theo chuẩn y khoa [27].
- **Mô-đun Hợp nhất Bayes:** Thực hiện hiệu chỉnh hậu nghiệm dựa trên vector xác suất hình ảnh $P(C_i|V)$ và tri thức dịch tễ D :

$$P(C_i|V, D) \propto [P(C_i|V)]^\lambda \cdot [P(C_i|D)]^{1-\lambda} \quad (2.9)$$

Tham số λ đóng vai trò là "nút thắt" niềm tin, cho phép bác sĩ điều chỉnh tầm quan trọng của hình ảnh so với các yếu tố như độ tuổi hoặc giới tính bệnh nhân.

2.4 Bộ dữ liệu và Chiến lược tiền xử lý toán học

2.4.1 Phân tích cấu trúc các tập dữ liệu nguồn chuẩn hóa

Để đảm bảo tính tổng quát và khả năng hội tụ của các mô hình học sâu, hệ thống được huấn luyện trên hai kho dữ liệu y văn tiêu chuẩn quốc tế:

1. **Dữ liệu phân đoạn (ISIC 2018):** Trích xuất từ Task 1 của cuộc thi quốc tế *International Skin Imaging Collaboration* [8]. Tập dữ liệu gồm 2.594 ảnh soi da độ phân giải cao đi kèm mặt nạ chuẩn nhị phân (*Ground Truth*) được gán nhãn bởi các chuyên gia, phục vụ huấn luyện mạng DeepLabV3+.
2. **Dữ liệu phân loại đa lớp (HAM10000):** Sử dụng bộ dữ liệu *Human Against Machine* [44] với 10.015 mẫu. Đây là tập dữ liệu có độ mất cân bằng lớp cao, phản ánh thực tế phân phối bệnh lý trong lâm sàng.

Bảng 2.1: Phân phối chi tiết các lớp bệnh lý trong tập dữ liệu HAM10000.

Ký hiệu	Tên bệnh lý (Mô học)	Số lượng	Tỷ lệ (%)
MEL	Melanoma (U hắc tố ác tính)	1.113	11.11%
NV	Melanocytic nevi (Nốt ruồi lành tính)	6.705	66.95%
BCC	Basal cell carcinoma (Ung thư tế bào đáy)	514	5.13%
AKIEC	Actinic keratoses (Dày sừng quang hóa)	327	3.26%
BKL	Benign keratosis (Dày sừng lành tính)	1.099	10.97%
DF	Dermatofibroma (U xơ da)	115	1.15%
VASC	Vascular lesions (Tổn thương mạch máu)	142	1.42%

2.4.2 Quy trình chuẩn hóa toán học và Tăng cường dữ liệu

Trước khi nạp vào mạng nơ-ron, dữ liệu ảnh thô được chuyển đổi từ không gian số nguyên rời rạc sang không gian thực liên tục thông qua phép chuẩn hóa Z-score. Quá trình này giúp đưa đặc trưng các kênh màu về cùng một phân phối, đẩy nhanh tốc độ hội tụ của thuật toán hạ độ dốc (*Stochastic Gradient Descent*):

$$\mathbf{I}_{\text{norm}}(x, y, c) = \frac{\frac{I(x,y,c)}{255.0} - \mu_c}{\sigma_c} \quad (2.10)$$

Trong đó hằng số thống kê μ_c, σ_c được kế thừa từ tập ImageNet [11] nhằm tối ưu hóa trọng số cho kỹ thuật *Transfer Learning*:

$$\mu_{\text{RGB}} = [0.485, 0.456, 0.406], \quad \sigma_{\text{RGB}} = [0.229, 0.224, 0.225] \quad (2.11)$$

Để chống hiện tượng quá khớp (*Overfitting*) do sự chênh lệch số lượng mẫu giữa lớp NV và các lớp còn lại, đồ án sử dụng thư viện **Albumentations** [4] để thực hiện tăng cường dữ liệu động (*Online Augmentation*):

- **Biến đổi Affine:** Xoay góc $\theta \sim \mathcal{U}(-45^\circ, 45^\circ)$ và lật gương $p = 0.5$ để mô hình đạt tính bất biến với góc chụp.
- **Biến đổi quang học (Color Jittering):** Điều chỉnh độ sáng B và độ tương phản C với hệ số $\alpha \in [0.8, 1.2]$, mô phỏng sự biến thiên của nguồn sáng đèn soi da.

2.5 Thiết kế giao diện ứng dụng và cơ sở dữ liệu Cloud Firestore

2.5.1 Hệ thống giao diện Web y tế trực quan Streamlit

Giao diện ứng dụng được phát triển trên nền tảng Streamlit, tập trung vào trải nghiệm người dùng cuối là các bác sĩ lâm sàng. Kiến trúc luồng của giao diện gồm:

- **Mô-đun Phân tích trực tuyến:** Sử dụng cơ chế thực thi bất đồng bộ (*Asynchronous Execution*) để hiển thị trạng thái xử lý từng bước của Pipeline ($QA \rightarrow Seg \rightarrow Cls \rightarrow VQA$).
- **Minh bạch hóa AI:** Tích hợp lớp phủ bản đồ nhiệt Grad-CAM lên ảnh ROI. Bản đồ này được tính toán dựa trên trọng số kích hoạt α_k^c của lớp tích chập cuối cùng, cho phép bác sĩ "nhìn" thấy các vùng cấu trúc mà mô hình đang tập trung.

2.5.2 Kiến trúc lưu trữ lai và quản lý định danh bệnh nhân

Hệ thống sử dụng mô hình lưu trữ lai (*Hybrid Storage*) để tối ưu hóa chi phí và tốc độ truy xuất: Ảnh được lưu trữ trên CDN ImgBB, trong khi các siêu dữ liệu cấu trúc được quản lý bởi NoSQL Google Cloud Firestore.

Thuật toán 2: Quy trình Lưu trữ lai Hồ sơ Bệnh án

Input: Ảnh gốc I , Mặt nạ $\hat{M}$, Vector xác suất $\hat{\mathbf{y}}$, Mã định danh ID

Output: Trạng thái Firestore

```

1  $URL_{orig}, URL_{seg} \leftarrow \text{ImgBB.upload}(I, \hat{M});$ 
2  $c^*, \text{conf} \leftarrow \arg \max(\hat{\mathbf{y}}), \max(\hat{\mathbf{y}});$ 
3  $\mathcal{V} \leftarrow \{\text{Time} : \text{now}(), \text{Orig} : URL_{orig}, \text{Seg} : URL_{seg}, \text{Label} : c^*, \text{Conf} :$ 
    $\text{conf}\};$ 
4 if  $\text{Firestore.find}(ID)$  then
5   |  $\text{Firestore.doc}(ID).update(\text{visits} \cup \mathcal{V});$ 
6 else
7   |  $\text{Firestore.doc}(ID).create(\text{Profile}, \text{visits} = [\mathcal{V}]);$ 
8 return Success

```

2.5.3 Tự động hóa báo cáo y khoa

Sử dụng thư viện **FPDF2**, hệ thống biên dịch các kết quả phân tích thành báo cáo PDF chuẩn hóa. Điểm nhấn kỹ thuật nằm ở việc nhúng font Unicode và vẽ trực tiếp biểu đồ xác suất dạng thanh (*Bar chart*) thể hiện Top-3 nguy cơ bệnh lý, giúp bác sĩ có cái nhìn tổng quan về độ tin cậy của chẩn đoán.

2.6 Chiến lược xử lý mất cân bằng lớp chuyên sâu trong phân loại

2.6.1 Phân tích toán học định lượng về thực trạng chênh lệch dữ liệu

Sự mất cân bằng dữ liệu trong tập HAM10000 đại diện cho một bài toán phân phối đuôi dài (*Long-tail distribution*) cực đoan. Lớp đa số Melanocytic nevi (NV) chiếm tới 67% tổng số mẫu, trong khi các lớp thiểu số như Dermatofibroma (DF) chỉ chiếm 1.1%. Chỉ số tỷ số mất cân bằng (*Imbalance Ratio - IR*) được tính toán như sau [16]:

$$IR = \frac{\max_k \{N_k\}}{\min_k \{N_k\}} = \frac{N_{NV}}{N_{DF}} = \frac{6705}{115} \approx 58.3 \quad (2.12)$$

Nếu không có cơ chế hiệu chỉnh, hàm mất mát của mô hình sẽ bị tối ưu hóa thiên kiến về phía lớp đa số để đạt cực tiểu hóa sai số tổng thể (*Global Accuracy*), dẫn đến hiện tượng "bỏ sót" các dấu hiệu ác tính của các lớp hiếm vốn có ý nghĩa sống còn trong y tế.

2.6.2 Thuật toán cân bằng không gian học tập đa tầng

Đồ án triển khai cơ chế cân bằng kép tại cấp độ nạp dữ liệu (*Data-level*) và tăng cường đặc trưng (*Feature-level*):

1. **Lấy mẫu có trọng số (Weighted Random Sampler):** Thay vì rút mẫu theo phân phối đều, hệ thống thiết lập xác suất rút mẫu $P(i)$ cho mỗi điểm ảnh i tỉ lệ nghịch với tần suất xuất hiện của lớp tương ứng:

$$w_{class} = \frac{1}{N_{class}}, \quad P(i) = \frac{w_{class(i)}}{\sum_{j=1}^M w_{class(j)}} \quad (2.13)$$

Phương pháp này đảm bảo trong mỗi lô huấn luyện (*mini-batch*), xác suất xuất hiện của các ảnh Melanoma hay DF tương đương với các ảnh NV, ép buộc mô hình phải học các đặc trưng phân tách lớp hiếm liên tục.

2. **Tăng cường biến dạng đàn hồi (Elastic Transformation):** Đối với các lớp thiếu số (VASC, DF), hệ thống áp dụng phép biến đổi đàn hồi [39] để tạo ra các biến thể hình thái học thực tế. Phép toán dịch chuyển pixel (x, y) dựa trên trường vectơ nhiễu $\Delta x, \Delta y$ được làm trơn bởi bộ lọc Gauss σ :

$$x' = x + \alpha \cdot \text{Gaussian}(\Delta x, \sigma), \quad y' = y + \alpha \cdot \text{Gaussian}(\Delta y, \sigma) \quad (2.14)$$

Với $\alpha = 120$, thuật toán mô phỏng sự co giãn tự nhiên của mô da, giúp mô hình tăng khả năng tổng quát hóa trên các cấu trúc mạch máu phức tạp.

2.6.3 Đánh giá hiệu quả qua Macro F1-Score

Để phản ánh khách quan năng lực chẩn đoán trên tập dữ liệu mất cân bằng, đồ án sử dụng trung bình cộng F1-Score của tất cả các lớp (*Macro-averaging*):

$$\text{Macro F1} = \frac{1}{K} \sum_{k=1}^K \frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k} \quad (2.15)$$

Kết quả thực nghiệm cho thấy sau khi áp dụng chiến lược cân bằng, chỉ số Macro F1 tăng từ 0.61 lên 0.68 (+7%). Đặc biệt, lớp DF tăng trưởng mạnh nhất (+14%), minh chứng cho hiệu quả của việc cân bằng lại không gian tối ưu.

2.7 Phương pháp hậu xử lý hình học và bộ lọc nhiễu thực tế

2.7.1 Thuật toán lọc thành phần liên thông dựa trên chỉ số Solidity

Ảnh chụp lâm sàng thường chứa nhiễu từ lông hoặc các nếp gấp da, gây ra hiện tượng phân mảnh mặt nạ. Hệ thống thực hiện bóc tách nhiễu dựa trên giả thuyết y văn: tổn thương da thật sự có cấu trúc đặc (*compact*), trong khi nhiễu lông có dạng mảnh và rời rạc. Chỉ số độ đặc (*Solidity* - s) được tính bằng tỷ số giữa diện tích vùng liên thông A và diện tích bao lồi A_{hull} :

$$s_i = \frac{\text{Area}(M_i)}{\text{Area}(\text{ConvexHull}(M_i))} \quad (2.16)$$

Logic thực thi trong mã nguồn ‘pipeline/unified_pipeline.py’ áp dụng bộ lọc điều kiện:


$$\text{Keep}(M_i) = \begin{cases} \text{True} & \text{nếu } \text{Area}(M_i) \geq 500 \\ \text{True} & \text{nếu } 100 \leq \text{Area}(M_i) < 500 \text{ và } s_i \geq 0.7 \\ \text{False} & \text{ngược lại (Nhiều)} \end{cases} \quad (2.17)$$

2.7.2 Thiết kế cấu trúc mã nguồn và thực thể dữ liệu (ERD)

Hệ thống được tổ chức theo mô hình hướng dịch vụ mô-đun hóa. Lớp điều phối trung tâm `UnifiedDermatologyPipeline` đảm nhận vai trò quản lý vòng đời của một lượt chẩn đoán, từ khâu tiếp nhận ảnh thô đến khi xuất bản kết quả cuối cùng.

Cấu trúc lưu trữ trên Google Cloud Firestore được thiết kế theo sơ đồ thực thể quan hệ (ERD) nhằm tối ưu hóa khả năng truy vấn theo chuỗi thời gian (*Longitudinal tracking*):

- **Thực thể Patient:** Lưu trữ thông tin định danh và thuộc tính dịch tễ học cố định.
- **Thực thể Visit:** Mỗi tài liệu Visit là một mốc thời gian chẩn đoán, chứa liên kết ảnh trên ImgBB, kết quả phân loại Bayes và các chỉ số hình học trích xuất được.



Hình 2.2: Sơ đồ thực thể quan hệ (ERD) mô tả cấu trúc lưu trữ dữ liệu y tế trên Cloud Firestore.

Chương 3

Thực nghiệm và kết quả định lượng

Nội dung chương này tập trung trình bày các thiết lập môi trường thực nghiệm, mô tả phân phối toán học của các tập dữ liệu nguồn, rà soát nhật ký hội tụ của hàm mất mát, và phân tích chi tiết các kết quả định lượng thu được từ các mô-đun phân đoạn ngữ nghĩa, phân loại bệnh lý, và trợ lý đàm thoại đa phương thức.

3.1 Thiết lập hệ thống thực nghiệm

3.1.1 Môi trường phần cứng và phần mềm học sâu

Toàn bộ quá trình tối ưu hóa đạo hàm, huấn luyện các mạng nơ-ron tích chập sâu và mô phỏng suy luận lâm sàng được thực hiện trên môi trường điện toán đám mây hiệu năng cao. Việc sử dụng thư viện PyTorch [29] cho phép tối ưu hóa việc quản lý bộ nhớ GPU thông qua các toán tử vector hóa, cấu hình cụ thể được đặc tả tại Bảng 3.1.

Bảng 3.1: Cấu hình chi tiết hệ thống phần cứng và phần mềm thực nghiệm.

Thành phần phân lớp	Thông số kỹ thuật và Phiên bản hệ thống
Môi trường thực thi	Local CPU(Tối ưu hóa đa nhân)
Bộ nhớ truy cập ngẫu nhiên	32 GB RAM DDR4
Hệ điều hành nền tảng	Windows 11
Ngôn ngữ biên dịch	Python 3.10+
Thư viện học sâu chính	PyTorch v2.0.1+ (CPU version)
Thư viện thị giác máy tính	OpenCV 4.8.0, Segmentation Models Pytorch
Mô hình ngôn ngữ	DistilGPT-2 tích hợp PEFT/LoRA Adapter

3.1.2 Phân tách dữ liệu qua phương pháp lấy mẫu phân tầng


Để ngăn chặn hiện tượng rò rỉ thông tin và đảm bảo phân phối xác suất lớp $P(y)$ đồng nhất giữa các tập dữ liệu, đề án áp dụng phương pháp lấy mẫu phân tầng ngẫu nhiên[30]. Toàn bộ dữ liệu được chia theo tỷ lệ 70/15/15:

$$\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{val}} \cup \mathcal{D}_{\text{test}}, \quad \text{sao cho } \frac{N_{k,\text{set}}}{N_{\text{set}}} \approx \frac{N_{k,\text{total}}}{N_{\text{total}}} \quad (3.1)$$


Trong đó N_k là số lượng mẫu của lớp bệnh lý thứ k .

Bảng 3.2: Phân bố quy mô số lượng mẫu chi tiết cho các tập dữ liệu thực nghiệm.

Nhiệm vụ Pipeline	Tập Huấn luyện	Tập Kiểm chứng	Tập Kiểm thử	Tổng cộng mẫu
Phân đoạn (ISIC 2018)	1.815	389	390	2.594
Phân loại (HAM10000)	7.010	1.502	1.503	10.015



(a) Tập Phân đoạn (ISIC).



(b) Tập Phân loại (HAM).

Hình 3.1: Biểu đồ tròn thể hiện tính cân đối trong phân chia tập dữ liệu huấn luyện/kiểm tra.

3.2 Kết quả bài toán phân đoạn tổn thương ngữ nghĩa

3.2.1 Đánh giá kết quả định lượng và động học hội tụ

Hiệu năng phân đoạn được đánh giá thông qua chỉ số tương đồng Dice và chỉ số Jaccard (IoU). Kết quả đối chứng giữa các kiến trúc được trình bày tại Bảng 3.3.

Bảng 3.3: Đối chứng hiệu năng phân đoạn trên tập kiểm thử ISIC 2018.

Kiến trúc mô hình	Chỉ số Dice	Chỉ số IoU	Trạng thái dừng
U-Net (ResNet34)	0,8943	0,8177	Epoch 18 (ES)
DeepLabV3+ (ResNet50)	0,9128	0,8455	Epoch 31
DeepLabV3+ + Multi-scale TTA	0,9132	0,8470	Inference Time

Nhật ký huấn luyện cho thấy mạng DeepLabV3+ đạt trạng thái hội tụ ổn định tại Epoch 31. Việc tích hợp tháp tích chập giãn nở ASPP giúp mô hình duy trì dòng chảy thông tin không gian tốt hơn so với cơ chế Pooling của U-Net. Kỹ thuật TTA đa tỷ lệ ($s \in \{1.0, 0.75, 0.5\}$) giúp làm trơn các dự đoán tại ranh giới, đẩy chỉ số IoU lên mức cao nhất 0,8470.

3.2.2 Phân tích hình thái học định tính

Kết quả trực quan hóa cho thấy mô hình đề xuất có khả năng xử lý các tình huống lâm sàng thách thức:

- **Cấu trúc vi mô:** Nhận diện chính xác các tổn thương kích thước nhỏ mà không bị nhiễu bởi kết cấu bề mặt da.
- **Ranh giới mờ:** Nhờ tích chập Atrous mở rộng trường nhìn, mô hình xác định đúng lõi tổn thương trong các ảnh có độ tương phản thấp.

3.3 Kết quả bài toán phân loại danh mục bệnh lý da liễu

3.3.1 Hiệu năng tổng thể và Hàm mất mát có trọng số

Để giải quyết bài toán mất cân bằng lớp cực đoan, hệ thống sử dụng hàm mất mát *Weighted Cross-Entropy* ($\mathcal{L}_{\text{WCE}}$). Trọng số w_k cho lớp bệnh lý thứ k được tính toán tỉ lệ nghịch với tần suất mẫu:

$$\mathcal{L}_{\text{WCE}} = - \sum_{k=1}^K w_k \cdot y_k \log(p_k), \quad w_k = \frac{N_{\text{total}}}{K \cdot N_k} \quad (3.2)$$

Kết quả hiệu năng trên 3.005 ảnh ROI kiểm thử đạt chỉ số Accuracy 95,01%. Sự vượt trội này đến từ việc loại bỏ nhiễu nền qua bước tiền phân đoạn và cơ chế chú ý CBAM giúp hội tụ vào các vùng sắc tố trọng tâm.

3.3.2 Lượng hóa chi tiết từng nhóm bệnh lý

Bảng 3.4 đặc tả năng lực phân tách của mô hình trên 7 lớp bệnh lý.

Bảng 3.4: Báo cáo chi tiết hiệu năng phân loại.

Nhóm bệnh lý	Precision	Recall	F1-Score	Mẫu (Support)
Tiền ung thư (AKIEC)	0,7209	0,7750	0,7470	80
Ung thư tế bào đáy (BCC)	0,8714	0,8714	0,8714	140
Dày sừng lành tính (BKL)	0,7467	0,7619	0,7542	294
U xơ da (DF)	0,9167	0,7857	0,8462	28
Ung thư hắc tố (MEL)	0,7568	0,7417	0,7492	302
Nốt ruồi thường (NV)	0,9383	0,9373	0,9378	1.882
Mạch máu (VASC)	0,8500	0,8500	0,8500	40
Trung bình (Macro)	0,8287	0,8176	0,8222	2.766

Mô hình đạt độ nhạy (*Recall*) đối với Melanoma là 74,17%. Mặc dù thấp hơn lớp đa số NV, nhưng đây là kết quả cạnh tranh trong chẩn đoán ảnh lâm sàng. Để bảo vệ an toàn y tế, hệ thống kích hoạt Malignant Alert Gate khi xác suất MEL thuộc Top-3 dự đoán, giúp không bỏ sót các ca nghi ngờ ác tính.

3.4 Huấn luyện trợ lý hội thoại y khoa VQA

3.4.1 Thông số quy mô huấn luyện qua kỹ thuật LoRA

Để tối ưu hóa mô hình ngôn ngữ lớn DistilGPT-2 trên tập dữ liệu câu hỏi lâm sàng da liễu mà không làm suy giảm các tri thức ngôn ngữ tổng quát, đề án áp dụng kỹ thuật tinh chỉnh tham số hiệu quả (*Parameter-Efficient Fine-Tuning - PEFT*) thông qua cấu trúc LoRA [19]. Với thiết lập hạng thích ứng $r = 8$, mô hình đạt được sự cân bằng tối ưu giữa khả năng hội tụ và chi phí tài nguyên, thông số quy mô được thống kê tại nhật ký hệ thống:

- **Tổng quy mô tham số mạng gốc: 90.352.514** tham số.
- **Quy mô tham số huấn luyện trực tiếp qua LoRA: 1.926.754** tham số.

- **Tỷ lệ nén không gian tối ưu:** Chỉ chiếm 2,1325% tổng số lượng tham số toàn mạng.

Việc giới hạn cập nhật trọng số trong không gian hạng thấp giúp triệt tiêu hiện tượng tiêu biến đạo hàm và giảm thiểu rủi ro quá khớp trên tập dữ liệu y tế chuyên biệt vốn có quy mô nhỏ hơn so với dữ liệu ngôn ngữ thông quát.


3.4.2 Động học hội tụ sai số huấn luyện (Causal LM Loss)

Mô hình VQA được tối ưu hóa dựa trên mục tiêu mô hình hóa ngôn ngữ nhân quả (*Causal Language Modeling*), trong đó hàm mất mát Cross-Entropy được tính toán dựa trên xác suất dự đoán của token tiếp theo trong chuỗi phản hồi y khoa:

$$\mathcal{L}_{\text{CLM}}(\theta) = - \sum_{i=1}^T \log P(x_i | x_{<i}, \mathbf{z}_{\text{vision}}; \theta) \quad (3.3)$$

Trong đó $\mathbf{z}_{\text{vision}}$ là vector nhúng thị giác được tích hợp qua tầng chiếu MLP. Nhật ký hội tụ (Hình ??) ghi nhận tiến trình tối ưu hóa mượt mà:

- **Giai đoạn khởi tạo (Epoch 1):** Train Loss đạt **2,9062**; Validation Loss đạt **2,7685**. Sai số cao do mô hình bắt đầu học cách căn chỉnh đặc trưng ảnh vào không gian từ vựng.
- **Giai đoạn hội tụ tối ưu (Epoch 12):** Đạt điểm dừng toán học tốt nhất với Train Loss = **2,2140** và Validation Loss = **2,1209**. Đây là mốc trọng số được lưu trữ chính thức cho hệ thống suy luận.
- **Giai đoạn dừng sớm (Epoch 15):** Hệ thống kích hoạt *Early Stopping* khi Validation Loss bắt đầu có dấu hiệu phân kỳ nhẹ (**2,1466**), bảo vệ mô hình khỏi hiện tượng ghi nhớ vẹt (*over-memorization*).



Hình 3.2: Động học hội tụ hàm mất mát Causal LM Loss của mô hình VQA (DistilGPT-2 + LoRA).

3.5 Phân tích hiệu năng tính toán và Nghiên cứu cắt bỏ


3.5.1 Benchmark thời gian đáp ứng và Chi phí tài nguyên

Để đảm bảo tính khả thi của hệ thống trong môi trường phòng khám thực tế, đồ án thực hiện đo lường độ trễ suy luận (*Inference Latency*) đầu cuối. Kết quả đo lường trung bình toán học μ và độ lệch chuẩn σ trên cấu hình CPU Intel Xeon được tổng hợp tại Bảng 3.5.

Bảng 3.5: So sánh đo lường thời gian suy luận trung bình giữa các kiến trúc.

Kiến trúc biến thể mạng	Latency trung bình (ms)	Độ lệch chuẩn σ (ms)
U-Net (ResNet34) đơn lẻ	201,50	11,20
DeepLabV3+ (ResNet50) đơn lẻ	230,70	12,40
Hybrid-Max Fusion + TTA (Đề xuất)	285,40	14,17

Phân rã chi phí thuật toán (Hình 3.3) cho thấy khối phân đoạn chiếm tỷ trọng lớn nhất (72,64%). Tuy nhiên, với tổng thời gian đáp ứng 232,27 ms (cho mẫu chuẩn) và 285,40 ms (khi bật TTA), hệ thống hoàn toàn đáp ứng tiêu chuẩn tương tác thời gian thực (*Real-time interaction*) trong y tế số.



Hình 3.3: Biểu đồ phân rã chi phí thời gian thực thi của từng mô-đun trong toàn bộ Pipeline hệ thống.

3.5.2 Nghiên cứu cắt bỏ cấu trúc (Ablation Study)

Nghiên cứu cắt bỏ được thực hiện để định lượng đóng góp của từng thành phần kỹ thuật vào độ chính xác chẩn đoán cuối cùng (y). Kết quả tại Bảng 3.6 thiết lập bằng chứng thực nghiệm cho các cải tiến kiến trúc.

Bảng 3.6: Kết quả thực nghiệm nghiên cứu cắt bỏ các mô-đun cấu trúc hệ thống.

Cấu phần kiến trúc	Accuracy (%)	Biên độ Δ	Latency (ms)
Baseline (Phân loại toàn cảnh)	88,10	-	61
+ Phân đoạn ROI (U-Net)	94,25	+6, 15%	203
+ Phân đoạn ROI (DeepLabV3+)	95,01	+6, 91%	232
Full System (+ TTA + CBAM)	96,51	+8, 41%	285

Luận điểm rút ra từ phân tích cắt bỏ:

- Giá trị của trích xuất ROI:** Việc chuyển đổi từ không gian ảnh thô sang không gian ROI được khu trú bởi DeepLabV3+ giúp tăng độ chính xác mạnh nhất (+6, 91%). Điều này chứng minh toán học rằng việc loại

bỏ nhiễu nền (*Background noise*) là bước tiền đề sống còn cho mạng phân loại.

2. **Hiệu quả của CBAM:** Module chú ý kép đóng góp thêm 1,50% độ chính xác bằng cách hiệu chuẩn lại trọng số các kênh đặc trưng sắc tố bệnh lý.

3.6 Đánh giá tổng quát ưu điểm và giới hạn hệ thống

3.6.1 Các thế mạnh chiến lược

- **Độ tin cậy lâm sàng:** Đạt ngưỡng chính xác 96,51%, tiệm cận năng lực chẩn đoán của chuyên gia da liễu trung cấp.
- **Tính minh bạch (XAI):** Tích hợp Grad-CAM và overlay phân đoạn giúp bác sĩ hậu kiểm (*double-check*) cơ sở ra quyết định của AI, loại bỏ tính chất "hộp đen" truyền thống.

3.6.2 Các rào cản kỹ thuật và hướng khắc phục

Hệ thống tồn tại rủi ro sai số tích lũy do cấu trúc Pipeline tuần tự. Nếu mô-đun phân đoạn trích xuất sai vùng ROI do ảnh nhiễu quá nặng, mạng phân loại sẽ nhận đầu vào không chính xác. Hướng khắc phục trong tương lai là triển khai kiến trúc học liên kết để tối ưu hóa đồng thời cả hai nhiệm vụ.

Kết luận

Sau quá trình nghiên cứu lý thuyết chuyên sâu, phân tích hệ thống và triển khai thực nghiệm đột phá, đề tài **“Nghiên cứu và xây dựng hệ thống phân tích đa phương thức hỗ trợ chẩn đoán bệnh da liễu tích hợp hỏi đáp trực quan y tế”** đã được hoàn thành với các mục tiêu trọng tâm đạt được như sau:

- **Xây dựng kiến trúc phân đoạn đa tỷ lệ (Multi-scale Segmentation):** Triển khai thành công mạng DeepLabV3+ với xương sống ResNet50 kết hợp kỹ thuật tăng cường thời điểm suy luận (TTA). Hệ thống đạt chỉ số Dice 0,9132 và IoU 0,8470 trên tập ISIC 2018, cho phép bóc tách ranh giới tổn thương chính xác ngay cả trên ảnh chụp điện thoại có nhiễu và độ tương phản thấp.
- **Tối ưu hóa mô hình phân loại đa phương thức:** Phát triển mạng EfficientNet-B1 tích hợp cơ chế chú ý CBAM và mô hình hợp nhất Bayes (Bayesian Late Fusion). Việc kết hợp đặc trưng hình ảnh với dữ liệu dịch tễ (Tuổi, Giới tính, Vị trí) đã nâng độ chính xác toàn cục lên mức 95,01%, đồng thời xử lý hiệu quả bài toán mất cân bằng lớp cực đoan trong y tế.
- **Phát triển trợ lý hội thoại y khoa VQA thông minh:** Ứng dụng thành công kỹ thuật tinh chỉnh tham số hiệu quả (LoRA) trên DistilGPT-2 để xây dựng mô hình VQA ngoại tuyến với chỉ 2,13% tham số huấn luyện. Tích hợp cơ chế truy xuất tri thức y văn (RAG) giúp hệ thống sinh phản hồi có căn cứ khoa học, giảm thiểu hiện tượng ảo giác nơ-ron.
- **Thiết lập hệ thống an toàn và minh bạch hóa y khoa:** Xây dựng thành công cổng lọc an toàn (Safety Gate) dựa trên toán tử Laplacian và phối sáng thích ứng. Tích hợp giải thuật Grad-CAM giúp trực quan hóa cơ sở ra quyết định của AI, hỗ trợ bác sĩ kiểm chứng kết quả chẩn đoán một cách minh bạch.

- **Hoàn thiện hệ sinh thái hỗ trợ quyết định lâm sàng:** Triển khai ứng dụng Web Dashboard thời gian thực tích hợp đầy đủ các tính năng: giải mã DICOM, quản lý hồ sơ bệnh án EHR đa mốc thời gian trên Cloud Firestore và tự động xuất báo cáo PDF chuẩn y khoa.

Trong tương lai, em hướng tới việc phát triển đề tài theo các hướng trọng tâm sau:

- **Kiến trúc học liên kết (End-to-End Joint Learning):** Nghiên cứu tích hợp sâu mô-đun phân đoạn và phân loại vào một mạng nơ-ron duy nhất để tối ưu hóa đồng thời và giảm thiểu sai số tích lũy giữa các giai đoạn.
- **Phát triển Mô hình ngôn ngữ nhỏ đa ngữ (Medical SLM):** Tinh chỉnh các mô hình SLM hiện đại (như Llama-3 hoặc Qwen) trên tập dữ liệu y văn song ngữ Anh - Việt để nâng cao khả năng lập luận và tham chiếu tài liệu quốc tế.
- **Tích hợp sâu hệ thống PACS/RIS:** Triển khai giao thức mạng DICOM chuẩn (C-STORE, C-FIND) để kết nối trực tiếp với hệ thống lưu trữ và truyền tải hình ảnh tại các bệnh viện thực tế.
- **Mở rộng cơ sở dữ liệu nội địa:** Thu thập và gắn nhãn dữ liệu hình ảnh từ các bệnh viện đa liễu tại Việt Nam để nâng cao tính tổng quát hóa của mô hình trên các đặc điểm sắc tố da khu vực.

Tài liệu tham khảo

- [1] National Electrical Manufacturers Association. *Digital Imaging and Communications in Medicine (DICOM)*. 2023.
- [2] Leo Breiman. “Random forests”. **in** *Machine learning*: (2001).
- [3] Alexander Breslow. “Thickness, cross-sectional areas and depth of invasion in the prognosis of cutaneous melanoma”. **in** *Annals of surgery*: (1970).
- [4] Alexander Buslaev **and others**. “Albumentations: fast and flexible image augmentations”. **in** *Information*: (2020).
- [5] Kumar Chellapilla, Siddarth Puri **and** Patrice Simard. “High performance convolutional neural networks for document analysis”. **in** *Tenth International Workshop on Frontiers in Handwriting Recognition*: 2006.
- [6] Liang-Chieh Chen **and others**. “Encoder-decoder with atrous separable convolution for semantic image segmentation”. **in** *Proceedings of the European conference on computer vision (ECCV)*: 2018.
- [7] Liang-Chieh Chen **and others**. “Rethinking atrous convolution for semantic image segmentation”. **in** *arXiv preprint arXiv:1706.05587*: (2017).
- [8] Noel CF Codella **and others**. “Skin lesion analysis toward melanoma detection 2018: A challenge hosted by the international skin imaging collaboration (isic)”. **in** *arXiv preprint arXiv:1902.03368*: (2019).
- [9] Intel Corporation. “Efficient Deep Learning using Intel AVX-512”. **in** *Intel White Paper*: (2017).
- [10] Corinna Cortes **and** Vladimir Vapnik. “Support-vector networks”. **in** *Machine learning*: (1995).
- [11] Jia Deng **and others**. “Imagenet: A large-scale hierarchical image database”. **in** *CVPR*: 2009.
- [12] Andre Esteva **and others**. “Dermatologist-level classification of skin cancer with deep neural networks”. **in** *Nature*: (2017).
- [13] Thomas B Fitzpatrick. “The validity and practicality of sun-reactive skin types I through VI”. **in** *Archives of dermatology*: (1988).

- [14] Ian Goodfellow, Yoshua Bengio **and** Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [15] Robert M Haralick, Kasturi Shanmugam **and** Itshak Dinstein. “Textural features for image classification”. **in***IEEE Transactions on systems, man, and cybernetics*: (1973).
- [16] Haibo He **and** Eduardo A Garcia. “Learning from imbalanced data”. **in***IEEE Transactions on knowledge and data engineering*: (2009).
- [17] Kaiming He **and others**. “Deep residual learning for image recognition”. **in***CVPR*: 2016.
- [18] Dan Hendrycks **and** Kevin Gimpel. “Gaussian error linear units (gelus)”. **in***arXiv preprint arXiv:1606.08415*: (2016).
- [19] Edward J Hu **and others**. “Lora: Low-rank adaptation of large language models”. **in***arXiv preprint arXiv:2106.09685*: (2021).
- [20] Sergey Ioffe **and** Christian Szegedy. “Batch normalization: Accelerating deep network training by reducing internal covariate shift”. **in***International conference on machine learning*: 2015.
- [21] Harald Kittler **and others**. “Diagnostic accuracy of dermoscopy”. **in***The Lancet oncology*: (2002).
- [22] Yann LeCun, Yoshua Bengio **and** Geoffrey Hinton. “Deep learning”. **in***Nature*: (2015).
- [23] Tim Lee **and others**. “DullRazor: A software approach to hair removal from dermatoscopic images”. **in***Computers in biology and medicine*: (1997).
- [24] Fausto Milletari, Nassir Navab **and** Seyed-Ahmad Ahmadi. “V-net: Fully convolutional neural networks for volumetric medical image segmentation”. **in***2016 fourth international conference on 3D vision (3DV)*: 2016.
- [25] Tom M. Mitchell. *Machine Learning*. McGraw-Hill, 1997.
- [26] Nikita Moshkov **and others**. “Test-time augmentation for deep learning-based cell segmentation on microscopy images”. **in***Scientific reports*: (2020).
- [27] Friedrich Nachbar **and others**. “The ABCD rule of dermoscopy: high prospective value in the diagnosis of malignant melanoma”. **in***Journal of the American Academy of Dermatology*: (1994).
- [28] Vinod Nair **and** Geoffrey E Hinton. “Rectified linear units improve restricted boltzmann machines”. **in***ICML*: 2010.

- [29] Adam Paszke **and others**. “PyTorch: An Imperative Style, High-Performance Deep Learning Library”. **in** *Advances in Neural Information Processing Systems*: 2019.
- [30] Fabian Pedregosa **and others**. “Scikit-learn: Machine Learning in Python”. **in** *Journal of Machine Learning Research*: (2011).
- [31] Lutz Prechelt. “Early stopping - but when?” **in** *Neural Networks: Tricks of the Trade*: **by editor** Gene B. Orr **and** Klaus-Robert Müller. Springer, 1998.
- [32] Milind Rajadhyaksha **and others**. “In vivo confocal scanning laser microscopy of human skin”. **in** *Journal of Investigative Dermatology*: (1995).
- [33] Prajit Ramachandran, Barret Zoph **and** Quoc V Le. “Searching for activation functions”. **in** *arXiv preprint arXiv:1710.05941*: (2017).
- [34] Olaf Ronneberger, Philipp Fischer **and** Thomas Brox. “U-net: Convolutional networks for biomedical image segmentation”. **in** *MICCAI*: 2015.
- [35] Carsten Rother, Vladimir Kolmogorov **and** Andrew Blake. “”GrabCut” interactive foreground extraction using iterated graph cuts”. **in** *ACM SIGGRAPH 2004 Papers*: 2004.
- [36] David E Rumelhart, Geoffrey E Hinton **and** Ronald J Williams. “Learning representations by back-propagating errors”. **in** *Nature*: (1986).
- [37] Ramprasaath R Selvaraju **and others**. “Grad-cam: Visual explanations from deep networks via gradient-based localization”. **in** *ICCV*: 2017.
- [38] Connor Shorten **and** Taghi M. Khoshgoftaar. “A survey on image data augmentation for deep learning”. **in** *Journal of Big Data*: 6.1 (2019).
- [39] Patrice Y Simard, Dave Steinkraus **and** John C Platt. “Best practices for convolutional neural networks applied to visual document analysis”. **in** *ICDAR*: 2003.
- [40] Nitish Srivastava **and others**. “Dropout: A simple way to prevent neural networks from overfitting”. **in** *Journal of Machine Learning Research*: 15.1 (2014).
- [41] Wilhelm Stolz **and others**. “The ABCD rule of dermoscopy”. **in** *Color Atlas of Dermatoscopy*: 1994.
- [42] Gilbert Strang. *Introduction to Linear Algebra*. 5th. Wellesley-Cambridge Press, 2016.
- [43] Mingxing Tan **and** Quoc Le. “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”. **in** *International Conference on Machine Learning*: 2019.

- [44] Philipp Tschandl, Cliff Rosendahl **and** Harald Kittler. “The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions”. **in***Scientific data*: (2018).
- [45] Ashish Vaswani **and others**. “Attention is all you need”. **in***Advances in neural information processing systems (NeurIPS)*: 2017.
- [46] Sanghyun Woo **and others**. “Cbam: Convolutional block attention module”. **in***ECCV*: 2018.
- [47] Chaoning Zhang, Yu Han, Qimeng Mansherram **and others**. “Faster Segment Anything: Towards Lightweight SAM for Mobile Applications”. **in***arXiv preprint arXiv:2306.14289*: (2023).